



Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное
образовательное учреждение высшего образования
«Национальный исследовательский Томский политехнический университет» (ТПУ)

Инженерная школа информационных технологий и робототехники
Направление подготовки: 09.04.01 Информатика и вычислительная техника
ООП/ОПОП: Искусственный интеллект и машинное обучение
Отделение школы (НОЦ): Отделение информационных технологий

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА МАГИСТРАНТА

Тема работы
Разработка алгоритма генерации текстового описания изображения на основе нейросетевых архитектур

УДК 004.912.032.26.021

Студент

Группа	ФИО	Подпись	Дата
8BM22	Ямкин Никита Николаевич		

Руководитель

Должность	ФИО	Ученая степень, звание	Подпись	Дата
Профессор ОИТ ИШИТР	Спицын В.Г.	д.т.н.		

Консультант

Должность	ФИО	Ученая степень, звание	Подпись	Дата
Старший преподаватель ОИТ ИШИТР	Кривошеев Н.А.			

КОНСУЛЬТАНТЫ ПО РАЗДЕЛАМ:

По разделу «Финансовый менеджмент, ресурсоэффективность и ресурсосбережение»

Должность	ФИО	Ученая степень, звание	Подпись	Дата
Профессор БШ	Жиронкин Сергей Александрович	д.э.н.		

По разделу «Социальная ответственность»

Должность	ФИО	Ученая степень, звание	Подпись	Дата
Профессор ОКД ИШНКБ	Федоренко Ольга Юрьевна	д.м.н.		

ДОПУСТИТЬ К ЗАЩИТЕ:

Руководитель ООП, должность	ФИО	Ученая степень, звание	Подпись	Дата
Профессор ОИТ ИШИТР	Спицын В.Г.	д.т.н.		

Томск – 2024 г.

ПЛАНИРУЕМЫЕ РЕЗУЛЬТАТЫ ОСВОЕНИЯ ООП

по направлению 09.04.01 Информатика и вычислительная техника

Код компетенции	Наименование компетенции
Универсальные компетенции	
УК(У)-1	Способен осуществлять критический анализ проблемных ситуаций на основе системного подхода, вырабатывать стратегию действий
УК(У)-2	Способен управлять проектом на всех этапах его жизненного цикла
УК(У)-3	Способен организовывать и руководить работой команды, вырабатывая командную стратегию для достижения поставленной цели
УК(У)-4	Способен применять современные коммуникативные технологии, в том числе на иностранном (-ых) языке (-ах), для академического и профессионального взаимодействия
УК(У)-5	Способен анализировать и учитывать разнообразие культур в процессе межкультурного взаимодействия
УК(У)-6	Способен определять и реализовывать приоритеты собственной деятельности и способы ее совершенствования на основе самооценки
Общепрофессиональные компетенции	
ОПК(У)-1	Способен самостоятельно приобретать, развивать и применять математические, естественно-научные, социально-экономические и профессиональные знания для решения нестандартных задач, в том числе в новой или незнакомой среде и в междисциплинарном контексте
ОПК(У)-2	Способен разрабатывать оригинальные алгоритмы и программные средства, в том числе с использованием современных интеллектуальных технологий, для решения профессиональных задач
ОПК(У)-3	Способен анализировать профессиональную информацию, выделять в ней главное, структурировать, оформлять и представлять в виде аналитических обзоров с обоснованными выводами и рекомендациями
ОПК(У)-4	Способен применять на практике новые научные принципы и методы исследований

ОПК(У)-5	Способен разрабатывать и модернизировать программное и аппаратное обеспечение информационных и автоматизированных систем
ОПК(У)-6	Способен разрабатывать компоненты программно-аппаратных комплексов обработки информации и автоматизированного проектирования
ОПК(У)-7	Способен адаптировать зарубежные комплексы обработки информации и автоматизированного проектирования к нуждам отечественных предприятий
ОПК(У)-8	Способен осуществлять эффективное управление разработкой программных средств и проектов
Профессиональные компетенции	
ПК(У)-1	Способен к созданию программного обеспечения для анализа, распознавания и обработки информации, систем цифровой обработки сигналов
ПК(У)-2	Способен проектировать сложные пользовательские интерфейсы
ПК (У)-3	Способен управлять процессами и проектами по созданию (модификации) информационных ресурсов
ПК (У)-4	Способен осуществлять руководство разработкой комплексных проектов на всех стадиях и этапах выполнения работ
ПК(У)-5	Способен проектировать и организовывать учебный процесс по образовательным программам с использованием современных образовательных технологий

Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное образовательное учреждение
высшего образования
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

Инженерная школа информационных технологий и робототехники
Направление подготовки: 09.04.01 Информатика и вычислительная техника
ООП/ОПОП: Искусственный интеллект и машинное обучение
Отделение школы (НОЦ): Отделение информационных технологий

УТВЕРЖДАЮ:
Руководитель ООП

(Подпись) _____ (Дата) Спицын В.Г.
(Ф.И.О.)

ЗАДАНИЕ
на выполнение выпускной квалификационной работы

В форме:

Магистерской диссертации
(бакалаврской работы, дипломного проекта/работы, магистерской диссертации)

Студенту:

Группа	ФИО
8BM22	Ямкин Никита Николаевич

Тема работы:

Разработка алгоритма генерации текстового описания изображения на основе нейросетевых архитектур	
Утверждена приказом директора (дата, номер)	№ 31-43/с от 31.01.2024

Срок сдачи студентом выполненной работы:	18.06.2024
--	------------

ТЕХНИЧЕСКОЕ ЗАДАНИЕ:

Исходные данные к работе (наименование объекта исследования или проектирования; производительность или нагрузка; режим работы (непрерывный, периодический, циклический и т. д.); вид сырья или материал изделия; требования к продукту, изделию или процессу; особые требования к особенностям функционирования (эксплуатации) объекта или изделия в плане безопасности эксплуатации, влияния на окружающую среду, энергозатратам; экономический анализ и т. д.).	Объектом исследования является генерация текстового описания изображения.
Перечень подлежащих исследованию, проектированию и разработке вопросов (аналитический обзор по литературным источникам с целью выяснения достижений мировой науки техники в	1. Обзор существующих методов генерации текстовых описаний изображений; 2. Анализ нейросетевых алгоритмов генерации текстовых описаний изображений;

<i>рассматриваемой области; постановка задачи исследования, проектирования, конструирования; содержание процедуры исследования, проектирования, конструирования; обсуждение результатов выполненной работы; наименование дополнительных разделов, подлежащих разработке; заключение по работе).</i>	3. Проектирование и разработка нейросетевого алгоритма; 4. Тестирование нейросетевого алгоритма; 5. Работа над разделом по финансовому менеджменту, ресурсоэффективности и ресурсосбережения; 6. Работа над разделом по социальной ответственности; 7. Работа над разделом на английском языке.
Перечень графического материала (с точным указанием обязательных чертежей)	1. Изображения примеров из набора данных; 2. Схемы структур нейронных сетей; 3. Таблицы для сравнения моделей; 4. Изображения с результатами работы нейросетевых алгоритмов.
Консультанты по разделам выпускной квалификационной работы (с указанием разделов)	
Раздел	Консультант
Финансовый менеджмент, ресурсоэффективность и ресурсосбережение	Профессор БШ, д.э.н., Жиронкин С.А.
Социальная ответственность	Профессор ОКД ИШНКБ, д.м.н., Федоренко О.Ю.
Раздел на иностранном языке	Старший преподаватель ОИЯ, Ануфриева Т.Н.
Названия разделов, которые должны быть написаны на иностранном языке:	
Обзор существующих методов	

Дата выдачи задания на выполнение выпускной квалификационной работы по линейному графику	02.02.2024
--	------------

Задание выдал руководитель:

Должность	ФИО	Ученая степень, звание	Подпись	Дата
Профессор ОИТ ИШИТР	Спицын В.Г.	д.т.н.		

Задание принял к исполнению студент:

Группа	ФИО	Подпись	Дата
8BM22	Ямкин Никита Николаевич		

Министерство науки и высшего образования Российской Федерации
федеральное государственное автономное образовательное учреждение
высшего образования
**«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
ТОМСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»**

Инженерная школа информационных технологий и робототехники
Направление подготовки: 09.04.01 Информатика и вычислительная техника
ООП/ОПОП: Искусственный интеллект и машинное обучение
Отделение школы (НОЦ): Отделение информационных технологий

Форма представления работы:

Магистерская диссертация
(бакалаврская работа, дипломный проект/работа, магистерская диссертация)

КАЛЕНДАРНЫЙ РЕЙТИНГ-ПЛАН
выполнения выпускной квалификационной работы

Срок сдачи студентом выполненной работы:	18.06.2024
--	------------

Дата контроля	Название раздела (модуля) / вид работы (исследования)	Максимальный балл раздела (модуля)
18.06.2024	Обзор существующих методов генерации текстовых описаний изображений;	10
18.06.2024	Анализ нейросетевых алгоритмов генерации текстовых описаний изображений;	30
18.06.2024	Проектирование и разработка нейросетевого алгоритма;	20
18.06.2024	Тестирование нейросетевого алгоритма;	20
18.06.2024	Работа над разделом по финансовому менеджменту, ресурсоэффективности и ресурсосбережения;	10
18.06.2024	Работа над разделом по социальной ответственности;	10

СОСТАВИЛ:
Руководитель ВКР

Должность	ФИО	Ученая степень, звание	Подпись	Дата
Профессор ОИТ ИШИТР	Спицын В.Г.	Д.Т.Н.		

СОГЛАСОВАНО:
Руководитель ООП

Должность	ФИО	Ученая степень, звание	Подпись	Дата
Профессор ОИТ ИШИТР	Спицын В.Г.	Д.Т.Н.		

Реферат

Выпускная квалификационная работа содержит пояснительную записку на 100 страницах, 38 рисунков, 21 таблицы, 55 источников литературы, 5 приложений.

Ключевые слова: компьютерное зрение, глубокое обучение, сверточные нейронные сети, рекуррентные нейронные сети, трансформер, механизм внимания, энкодер, декодер, генерация текста, метрики оценки качества.

Целью данной работы является разработка и исследование алгоритмов генерации текстового описания изображения на основе нейросетевых архитектур. Для достижения данной цели необходимо: проанализировать существующие методы генерации текстового описания, выбрать подходящие модели для реализации, выбрать набор данных, реализовать модели, произвести обучение и тестирование.

В рамках исследования проводился анализ существующих нейросетевых моделей для генерации текстового описания изображения, на основании которого были выбраны три архитектуры моделей для дальнейшей реализации.

Далее были реализованы все три архитектуры и проведено их тестирование, показавшее обнадеживающие результаты по качеству генерации описаний. Исходя из полученных результатов была выбрана наиболее эффективная модель.

Оглавление

Введение	5
1 Обзор существующих методов	7
1.1 Актуальность задачи	7
1.2 Традиционные подходы	7
1.3 Подходы с использованием нейросетей	9
1.3.1 CNN +LSTM	9
1.3.2 CNN + Transformer Decoder	10
1.3.3 CNN + Transformer	11
1.4 Вывод	12
2 Анализ использованных сверточных нейронных сетей в моделях генерации текстового описания изображения	13
2.1 VGG-16	13
2.2 EfficientNetV2	15
2.3 ResNet18	16
2.4 Вывод	18
3 Анализ использованных алгоритмов генерации текста для создания описаний изображений	18
3.1 LSTM	19
3.2 Attention	24
3.3 Self - Attention	27
3.3.1 Self – Attention. Encoder	28
3.3.2 Self – Attention. Decoder	30
3.4 Multi-head attention	31
3.5 Transformer	32
3.5.1 Transformer Encoder	34
3.5.2 Positional Encoding	38
3.5.3 Transformer Decoder	39
3.6 Вывод	43
4 Метрики	44
4.1 BLEU	44
4.2 BERT score	44
5 Датасет	45
6 Результаты применения нейросетевых алгоритмов для генерации текстовых описаний изображений	46
6.1 Эксперимент №1	46
6.2 Эксперимент №2	51
6.3 Эксперимент №3	53
6.4 Вывод	55
7 Финансовый менеджмент, ресурсоэффективность и ресурсосбережение	57

7.1 Предпроектный анализ	57
7.1.1 Потенциальные потребители результатов исследования	57
7.1.2 Анализ конкурентных технических решений с позиции ресурсоэффективности и ресурсосбережения	58
7.1.3 SWOT-анализ	60
7.2 Планирование научно-исследовательских работ	61
7.2.1 Структура работ в рамках научного исследования	61
7.2.2 Определение трудоемкости выполнения работ	62
7.2.3 Разработка графика проведения научного исследования	62
7.2.4 Бюджет научно-технического исследования	65
7.3 Определение ресурсной (ресурсосберегающей), финансовой, бюджетной, социальной и экономической эффективности исследования	69
7.4 Выводы по разделу	72
8 Социальная ответственность	76
8.1 Введение	76
8.2 Правовые и организационные вопросы обеспечения безопасности	77
8.2.1 Правовые нормы трудового законодательства	77
8.2.2 Эргономические требования к рабочему месту	78
8.3 Производственная безопасность	79
8.3.1 Анализ вредных факторов	80
8.3.1.1 Повышенный уровень и другие неблагоприятные характеристики шума	80
8.3.1.2 Факторы, связанные с аномальными микроклиматическими параметрами воздушной среды	81
8.3.1.3 Повышенный уровень общей вибрации	82
8.3.1.4 Отсутствие или недостаток необходимого искусственного освещения	83
8.3.2 Анализ опасных факторов	86
8.3.2.1 Факторы, связанные с электрическим током	86
8.4 Экологическая безопасность	87
8.5 Безопасность в чрезвычайных ситуациях	89
8.6 Вывод	92
Заключение	93
Список использованных источников	94
ПРИЛОЖЕНИЕ А	100
ПРИЛОЖЕНИЕ Б	109
ПРИЛОЖЕНИЕ В	112
ПРИЛОЖЕНИЕ Г	115
ПРИЛОЖЕНИЕ Д	118
ПРИЛОЖЕНИЕ Е	119

Введение

Большинство окружающей нас информации представлено в одном из двух видов: графическом (визуальная информация: фото и видео) и текстовом (письменный или устный текст на естественном языке).

Количество информации обоих видов, с которой сталкиваются пользователи информационных технологий каждый день, растет с постоянно увеличивающейся скоростью.

Так, согласно статистике [1], большая часть мирового трафика данных приходится на видео (53.72%), а на втором месте по количеству создаваемых данных находятся социальные сети – 12.69%. При этом, информация в виде текстов на естественном языке является более привычной и удобной для коммуникации между людьми.

В связи с этим возрастает интерес к комплексным задачам искусственного интеллекта, которые предполагают совместную обработку разнородной информации: как графической, так и текстовой. Подобные задачи и методы их решения называют мультимодальными [2].

Одной из таких задач является генерация текстового описания изображения, которая находится на стыке двух областей анализа данных: теории распознавания образов и обработки естественного языка.

Интерес к исследованиям в данной области связан с многочисленными практическими потребностями, а также ее огромным потенциалом. Вот некоторые из примеров, где решение данной задачи может быть применимо:

1. Эффективный поиск изображений или видео в больших коллекциях на основе их визуального содержания;
 2. Помощь слабовидящим людям (подразумевается использование в том числе голосового помощника);
 3. Системы автоматического управления технологическими процессами (промышленные роботы, автономные транспортные средства)
- [2].

Цель работы: разработка и исследование алгоритмов генерации текстового описания изображения на основе нейросетевых архитектур.

Объект исследования: генерация текстового описания изображения.

Предмет исследования: алгоритмы генерации текстового описания изображения на основе нейросетевых архитектур.

Задачи:

1. Обработать исходный набор данных для дальнейшего обучения и тестирования нейросетей;
2. Реализовать алгоритм текстового описания изображения на основе CNN и LSTM;
3. Реализовать алгоритм текстового описания изображения на основе CNN и Transformer decoder;
4. Реализовать алгоритм текстового описания изображения на основе CNN и Transformer;
5. Сравнить качество генерируемых описаний в каждом из подходов.

1 Обзор существующих методов

1.1 Актуальность задачи

С появлением социальных сетей количество создаваемого медиаконтента резко возросло. Это создало потребность в эффективных способах организации данных такого рода внутри хранилищ и извлечения их из них. Одним из подходов к решению поставленной проблемы является хранение изображений вместе с их описаниями.

Поскольку описания отражают информацию о визуальном содержании изображений, это позволяет выполнять поиск по соответствующим ключевым словам на естественном языке.

Однако, вручную «расшифровывать» большой объем изображений и видео слишком долго, дорого и неэффективно. В связи с этим возникает необходимость в автоматической генерации текстового описания с помощью математических моделей.

1.2 Традиционные подходы

Предполагаемый принцип работы такой: модель получает на вход картинку, анализирует её содержание и на выходе выдает её характеристику в виде одного или нескольких предложений.

Изначально проблема автоматической генерации решалась без использования глубокого обучения, а все методы были основаны на определенных правилах формирования ответов и на статистике.

Одним из первых таких подходов является алгоритм, разработанный в 2010 году командой Farhadi et al (статья Every Picture Tells a Story: Generating Sentences from Images). Предложенная модель использует промежуточное пространство в формате <объект, действие, сцена>, которое отражает смысл и изображения, и описания. В результате, входные данные отображаются в данное пространство и затем оценивается семантическая схожесть между

ними. Наконец, в качестве заголовка изображения используется семантически наиболее близкое предложение (рисунок 1).

Для обучения этой модели используется датасет PASCAL1K, в котором собраны триплеты <объект, действие, сцена>, изображения и описания.



Рисунок 1 – Иллюстрация пространства изображений, промежуточного пространства и пространства описаний [3]

Второй не нейросетевой подход для решения поставленной задачи основывался на механизме шаблонов.

В 2013 году команда Kulkarni et al впервые использовала алгоритмы компьютерного зрения в связке с графовой системой для генерации описаний (рисунок 2) [4].




Рисунок 2 – Иллюстрация алгоритма команды Kulkarni et al [4]

Принцип работы заключается в следующем: сначала детектируются объекты на изображении, каждому из которых присваиваются атрибуты, отражающие их свойства. Затем каждая пара детектированных объектов сравнивается между собой для оценки взаимосвязи. После этого строится

Conditional Random Field (CRF) граф, узлами которого являются сами объекты, их взаимосвязь и свойства. На выходе CRF-модели, получаем предсказание последовательности из объектов, атрибутов и взаимоотношений двух объектов. Далее предсказанная последовательность используется для формирования предложения, с помощью готовых шаблонов.

Приведенные традиционные способы имеют ряд общих недостатков:

- всегда генерируют шаблонный и, зачастую, несвязный текст;
- некоторые из них основываются на ручном извлечении признаков из изображений;
- не способны учитывать сложные, нелинейные взаимосвязи и зависимости между различными аспектами изображений и текста;
- сильно ограничены в масштабируемости.

Применение нейросетей позволяет избежать данных ограничений.

1.3 Подходы с использованием нейросетей

1.3.1 CNN +LSTM

В 2015 году Oriol Vinyals et al., в статье [5], предложил Neural Image Caption (NIC) модель, которая объединяет в себе CNN и RNN архитектуры (рисунок 4).

Идея состоит в том, чтобы использовать архитектуру CNN в качестве энкодера изображения, который будет кодировать изображение в вектор его признаков фиксированной длины. Для этого в классической CNN для классификации изображений убирается последний слой.

В качестве модели для генерации текста используется архитектура LSTM. При этом векторы скрытых состояний инициализируются выходами из CNN (рисунок 3).




Рисунок 3 – Пайплайн для Image Captioning [6]




Рисунок 4 – Архитектура NIC [5]

В период с 2015 по 2018 год архитектура NIC дорабатывалась: исследовались её различные модификации, методы обучения и метрики оценки качества генерируемого текста.

Дальнейшее улучшение качества формирования описания к изображению заключалось в интегрировании механизма внимания.

1.3.2 CNN + Transformer Decoder

В 2017 году была представлена архитектура Transformer.

Следующим этапом развития стала адаптация трансформера для решения рассматриваемой задачи.

Zhu et al. в 2018 году модифицировал архитектуру, заменив стандартный энкодер трансформера на CNN модель (рисунок 5) [7].

Принцип действия модели схож с NIC, только теперь признаки изображения подаются на слой Multi-Head Attention в декодер трансформера.




Рисунок 5 – Архитектура нейросети [7]

1.3.3 CNN + Transformer

Ещё одну модификацию в 2018 году предложил Zhang et al (рисунок 6). В этом варианте выход с CNN модели подается на блок энкодера в трансформере. Это делает возможным моделирование зависимостей между разными признаками изображения, что улучшает качество работы всей модели.




Рисунок 6 – Архитектура нейросети [8]

1.4 Вывод

Традиционные подходы к задаче Image Captioning имеют ряд существенных ограничений: они генерируют шаблонный и зачастую несвязный текст, основаны на ручном извлечении признаков из изображений, не способны учитывать сложные нелинейные зависимости между изображением и текстом, а также плохо масштабируемы.

В отличие от традиционных методов, применение нейросетевых архитектур позволяет преодолеть данные ограничения и добиться более гибкого и содержательного описания изображений. В рамках данной работы будет реализовано и исследовано три различных нейросетевых подхода к задаче Image Captioning.

2 Анализ использованных сверточных нейронных сетей в моделях генерации текстового описания изображения

Сверточные нейронные сети представляют собой тип глубоких нейронных сетей, специально разработанных для обработки изображений и видео. Такие нейросети широко используются в различных задачах компьютерного зрения, включая распознавание объектов, сегментацию и генерацию изображений.

В этой главе исследуются использованные в работе CNN архитектуры для решения задачи Image Captioning. В частности, описываются основные преимущества и недостатки трех широко используемых моделей: VGG16, ResNet18 и EfficientNetV2-S.

2.1 VGG-16

VGG-16 – это одна из наиболее популярных и широко используемых архитектур глубоких нейронных сетей для задач компьютерного зрения. Она была разработана группой исследователей из Оксфордского университета во главе с К. Simonyan и А. Zisserman в 2014 году [9]. Модель достигает точности 92,7 % при тестировании на датасете ImageNet в задаче распознавания объектов на изображении.

Одним из её достоинств является довольно простая структура: сеть представляет собой стек последовательно чередующихся свёрточных и пулинговых слоев. После этого идут три полносвязных слоя: первые два имеют по 4096 каналов, третий — 1000 каналов. Последним идет softmax слой [10].

При использовании предварительно обученной модели VGG-16 в качестве экстрактора визуальных признаков для задачи генерации текстовых описаний, целесообразно удалить последний полносвязный слой сети. Это объясняется тем, что он нужен для выполнения классификации изображений, для которой модель была первоначально обучена.

Первые два полносвязных слоя VGG-16 содержат информацию о высокоуровневых визуальных характеристиках объектов на картинке, таких как форма, текстура и семантические концепты. Эта информация может быть полезна для генерации более точных и связных текстовых описаний, поэтому эти слои были сохранены.

Таким образом, используемая в работе CNN модель без последнего полносвязного слоя проиллюстрирована на рисунке 7.




Рисунок 7 – Используемая в работе модель VGG16 без последнего полносвязного слоя [10]

Другое преимущество заключается в том, что ядра свёрточных слоев в VGG-16 имеют размер 3x3, что позволяет эффективно захватывать локальные пространственные зависимости в данных.

Главным недостатком рассматриваемой сети является большое количество обучаемых параметров (138 миллионов), что делает обучение и использование сети слишком долгим.

2.2 EfficientNetV2

EfficientNet V2 – это сверточная нейронная сеть, которая отличается высокой скоростью обучения и использованием более оптимизированных вычислительных блоков, чем предыдущая версия этой модели. Это достигается в результате сочетания методов масштабирования изображений и автоматического поиска наиболее оптимальной архитектуры сети (Neural Architecture Search, NAS).

NAS, используя алгоритмы машинного обучения (в данном случае RNN), автоматически оптимизирует структуру нейросети под конкретную задачу и датасет, что улучшает её общую производительность.

Авторы статьи также используют так называемый *progressive learning* – метод обучения, при котором постепенно увеличивается размер изображения, с применением дропаута и аугментации. Это еще больше ускоряет процесс обучения модели [11].

Основные отличия по сравнению с первой версией EfficientNet заключаются в следующем:

- В EfficientNet V2 используется как MBConv блоки, так и новые fused-MBConv блоки.
- В EfficientNet V2 установлен меньший коэффициент расширения в блоке MBConv для сокращения затрат по памяти.
- EfficientNet V2 использует меньшие размеры ядра (3x3), но добавляет больше слоев, для компенсации (рисунок 8) [12].




Рисунок 8 – Архитектура используемой сети EfficientNet V2-S [13]

Часть (а). Цифры справа – количество слоев, цифры снизу – шаг ядра (stride) и количество каналов на выходе слоя.

Часть (b–e) – это схема каждого блока в части (а) – Fused-MBConv1, Fused-MBConv4 ($k3 \times 3$), MBConv4($k3 \times 3$) и MBConv6 ($k3 \times 3$), соответственно [13].

EfficientNet V2-S имеет 24 миллиона обучаемых параметров [11].

2.3 ResNet18

ResNet18 — это глубокая сверточная нейронная сеть с 18 блоками, которая была представлена в статье [14] в 2015 году. Данная сеть является

одной из самых популярных архитектур CNN благодаря своей высокой точности и эффективности (рисунок 10).

ResNet18 состоит из нескольких остаточных («residual») блоков (рисунок 9). Каждый такой блок содержит два сверточных слоя с соединением между ними. Оно позволяет градиентам легко проходить через сеть во время обратного распространения ошибки, что помогает избавиться от проблемы затухающих градиентов, которая часто встречается в глубоких нейронных сетях.




Рисунок 9 – Структура остаточного блока сети [14]

Количество обучаемых параметров в ResNet18 – 10 857 784. Размер ядра 3x3, количество выходных каналов изменяется с 64 до 512.




Рисунок 10 – Архитектура ResNet18 [15]

Для того, чтобы рассмотренная CNN была применима к задаче генерации текстовых описаний необходимо также избавиться от последнего полносвязного слоя.

2.4 Вывод

В данном разделе был проведен обзор трех различных CNN-архитектур, которые будут использованы в качестве визуальных энкодеров. Рассмотренные архитектуры включают VGG16, ResNet18 и EfficientNet V2.

VGG16 является классической и широко применяемой CNN-моделью, отличающейся простой и глубокой структурой, и имеет около 138 миллионов параметров.

ResNet18 представляет собой более современную архитектуру, использующую концепцию остаточных связей. Это позволяет эффективно обучать глубокие нейронные сети, не страдающие от проблемы затухания градиентов. ResNet18 имеет существенно меньшее количество параметров по сравнению с VGG16 - около 11 миллионов.

Наиболее передовой из рассмотренных архитектур является EfficientNet V2, которая отличается высокой эффективностью и компактностью. Данная модель насчитывает около 22 миллионов параметров.

3 Анализ использованных алгоритмов генерации текста для создания описаний изображений

Как уже было отмечено ранее, многие подходы к созданию текстовых описаний изображений основаны на архитектуре энкодер-декодер. Энкодер преобразует изображение в вектор признаков, который затем декодируется в текстовое описание с помощью декодера.

Задачу «декодирования» можно сформулировать следующим образом: требуется найти наиболее вероятную последовательность токенов на английском языке при условии поданного на вход вектора признаков изображения. В виде формулы это будет выглядеть так:

$$\widehat{target} = \operatorname{argmax} P(target | source, \theta) \quad (3.1)$$

где $\widehat{target}$ – предсказанное моделью описание, $source$ – вектор признаков изображения, θ – параметры модели.

В результате применения функции $\text{argmax}()$, выбирается только одна, максимальная по вероятности, последовательность токенов, которую может сгенерировать нейронная сеть.

Более подробно приведенная выше формула выглядит так:

$$\begin{aligned} P(\text{target} | \text{source}, \theta) &= P(y_1, y_2, y_3, \dots, y_m | \text{source}, \theta) = \\ &= P(y_1 | \text{source}, \theta) \cdot P(y_2 | y_1, \text{source}, \theta) \cdot \dots \\ &\cdot P(y_m | y_1, \dots, y_{m-1}, \text{source}, \theta) \end{aligned} \quad (3.2)$$

Выражение (3.2) представляет собой произведение условных вероятностей сгенерированных токенов, при условии вектора признаков изображения и предыдущих сгенерированных токенов.

Тогда декодер, по сути, является условной языковой моделью, в качестве которой, в данной работе, выступают LSTM и Transformer. Далее рассмотрим принцип их работы.

3.1 LSTM

Отличие текста и звука от других типов данных (например, изображений) состоит в наличии временной компоненты. Соответственно, такая информация обрабатывается не моментально, а в определенном порядке.

Рекуррентные нейронные сети учитывают эту особенность и обрабатывают один токен текста в каждый момент времени.

Одной из вариаций стандартного рекуррентного слоя является Long Short Term Memory (LSTM) сеть, которая была придумана для того, чтобы решить проблему «забывания» информации в RNN (рисунок 11).




Рисунок 11 – LSTM-ячейка [16]

На рисунке C_t (*cell*) – вектор долгосрочной памяти, h_t – вектор краткосрочной памяти или текущее состояние слоя, x_t – вектор входных данных. Все эти векторы имеют одинаковую размерность.

Разберем принцип работы LSTM по порядку.

1) В каждый момент времени t , LSTM может удалять информацию из памяти C_t (операция поэлементного умножения), либо записывать в нее новую (операция поэлементного сложения, рисунок 12).




Рисунок 12 – Удаление и запись информации в долгосрочную память C_t [17]

2) «Ворота забывания» («forget gate», рисунок 13)




Рисунок 13 – «Ворота забывания» [17]

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (3.3)$$

$$C_t^{temp} = f_t \cdot C_{t-1} \quad (3.4)$$

Выражение (3.3): берем текущее состояние краткосрочной памяти h_{t-1} и новую информацию x_t , пришедшую на вход. Конкатенируем эти два вектора и пропускаем через полносвязный слой с функцией активации сигмоида. На выходе слоя получаем вектор значений f_t от 0 до 1, выражающий ту часть информации вектора C_{t-1} , которую надо «забыть».

Выражение (3.4): берем полученный ранее вектор f_t и поэлементно умножаем его на вектор C_{t-1} . В итоге, каждый элемент вектора C_{t-1} умножается на значение от 0 до 1. Таким образом делаем информацию, содержащуюся в каждом элементе долгосрочной памяти, менее выраженной. Это и есть процесс забывания.

3) «Ворота входа» («input gate», рисунок 14)




Рисунок 14 – «Ворота входа» [17]

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (3.5)$$

$$C_t^{add} = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \quad (3.6)$$

$$C_t = C_t^{temp} + i_t \cdot C_t^{add} \quad (3.7)$$

Выражение (3.5) аналогично выражению (3.3): пропускаем через полносвязный слой с функцией активации сигмоида результат конкатенации вектора краткосрочной памяти h_{t-1} и данных со входа x_t . На выходе слоя получаем вектор значений i_t от 0 до 1. Вектор i_t – это вектор весов для C_t^{add} , он определяет, насколько сильно каждый элемент в C_t^{add} нужен в долгосрочной памяти C_t .

Выражение (3.6): пропускаем через полносвязный слой с функцией активации $\tanh()$ конкатенированные векторы h_{t-1} и x_t . На выходе слоя получаем вектор дополнительной информации C_t^{add} , которую мы хотим добавить в долгосрочную память C_t .

Выражение (3.7): обновляем вектор C_t , на основе вычислений в «воротах забывания» и в «воротах входа» в момент времени t (рисунок 15).




Рисунок 15 – Обновление долгосрочной памяти [17]

4) Следующий шаг – обновление вектора h_t и вычисление выхода слоя (рисунок 16).




Рисунок 16 – Обновление краткосрочной памяти [17]

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (3.8)$$

$$h_t = o_t \cdot \tanh(C_t) \quad (3.9)$$

Идея: чтобы вычислить ответ слоя в момент времени t , не нужно знать всю информацию, которая хранится в долгосрочной памяти C_t , достаточно знать только какую-то часть этой информации.

o_t – это также вектор значений в интервале от 0 до 1, характеризующий ту часть информации, которая переносится из C_t в h_t .

В пункте 1 – 4 был рассмотрен полный цикл операций, происходящий в LSTM блоке на каждом шаге t .

Стоит отметить, что сеть довольно долго обучается, т.к. в ней четыре обучаемых матрицы (W_f, W_i, W_C, W_o).

Основные этапы обучения LSTM-сети приведены ниже:

- 1) Взять большой корпус текста, разбить его на отдельные последовательности токенов $x_0, x_1, x_2, \dots, x_k$.
- 2) Подать эти последовательности на вход LSTM и получить вероятностное распределение $\hat{y}_0, \hat{y}_1, \hat{y}_2, \dots, \hat{y}_k$ на выходе.
- 3) Посчитать loss-функцию, в данной работе это кросс-энтропия, между предсказанием $\hat{y}_0, \hat{y}_1, \hat{y}_2, \dots, \hat{y}_k$ и истинным распределением $y_0, y_1, y_2, \dots, y_k$.
- 4) Оптимизировать градиентным спуском.

Как уже было отмечено ранее, LSTM была придумана для того, чтобы нивелировать «забывание» информации в RNN. В данной архитектуре вся

информация хранится в векторе C_t , к которому что-то либо прибавляется, либо отнимается. В результате, на каждой итерации t содержимое C_t изменяется незначительно, что помогает в борьбе с затуханием градиентов.

Однако даже такой механизм не позволил в полной мере избавиться от этого недостатка, хотя он и стал мене выраженным, чем в стандартной рекуррентной сети.

Итак, основными минусами LSTM остаются:

- 1) «Забычивость»: декодер на основе этой сети может забывать начало длинных предложений;
- 2) Вся информация о длинном предложении записывается в один вектор;
- 3) Невозможность эффективного обучения на GPU, т.к. данная модель работает только последовательно и её нельзя распараллелить.

Механизм внимания помогает решить указанные проблемы.

3.2 Attention

Механизм внимания — это мощная техника, которая произвела революцию в области NLP и других задачах обработки последовательностей.

Идея механизма была предложена в 2014 году в статье [18] в ответ на ограничения RNN в задаче машинного перевода, и заключается в том, что внимание позволяет нейронным сетям сосредоточиться на наиболее важных частях входной последовательности.

Рассмотрим работу внимания на примере архитектуры Encoder-Decoder с рекуррентными нейронными сетями (рисунок 17). В этом примере энкодер преобразует предложение на английском языке в вектор фиксированной длины. Затем декодер использует этот вектор для последовательного вывода переведенного предложения на русском языке.




Рисунок 17 – Пример работы механизма Attention в задаче машинного перевода [19]

В начальный момент времени t находимся на шаге h_{d0} (токен "<bos>") и хотим перевести следующее слово.

Что делает attention?

1) На вход функции внимания подается скрытое состояние декодера h_{d0} и скрытые состояния энкодера в каждый момент времени.

2) По результатам вычисления функции для каждого состояния энкодера и h_{d0} , на выходе будет некоторое значение – score. В примере на рисунке 17 в исходном предложении пять токенов, следовательно функция внимания применяется пять раз.

3) Далее, получаем распределение вероятностей на слова в изначальном предложении, в результате применения функции активации *softmax* к полученным ранее значениям. Распределение вероятностей выражает то, насколько важно декодеру в данный момент времени «посмотреть» на

соответствующий токен в исходном предложении, чтобы перевести первое слово.

4) Затем, на основе полученных вероятностей w_i и скрытых состояний энкодера, вычисляется вектор контекста c :

$$c = w_0 \cdot h_0 + w_1 \cdot h_1 + \dots + w_4 \cdot h_4 \quad (3.10)$$

5) Вычисленный вектор контекста c подается на вход декодеру вместе с эмбедингом специального токена $\langle bos \rangle y_1$.

6) Теперь распределение вероятностей на следующее слово в декодере будет рассчитано исходя из вектора y_1 , вектора контекста c и вектора h_{d0} .

$$out = g([y_1, c], h_{d0}) \quad (3.11)$$

Таким образом, механизм attention выделит из энкодера ту информацию, которая понадобится декодеру в соответствующий момент времени t для генерации следующего слова перевода.

Интуитивный смысл механизма здесь такой: процесс перевода человеком длинных текстов с одного языка на другой предполагает возможность многократного обращения к исходному тексту. Это связано с тем, что переводчик не рассчитывает на возможность однократного прочтения и запоминания исходного материала.

При этом сама функция внимания может быть разной. Например, это может быть скалярное произведение или что-то другое. В статье «Attention is all you need» [20] используется QKV Attention.




Рисунок 18 – График оценки качества генерации текста разной длины [18]

На рисунке 18 проиллюстрировано влияние механизма внимания на качество генерации текста. По сплошной линии видно, что даже при большой длине последовательности качество генерируемого текста, а именно метрика BLEU, не ухудшается. Так происходит потому, что Attention позволяет «заглядывать» в любую часть исходного предложения, независимо от его длины.

3.3 Self - Attention

Self-attention позволяет модели сосредоточиться на наиболее важных частях либо внутри входной последовательности, либо внутри выходной, в отличие от простого механизма attention.

Простыми словами данная техника помогает идентифицировать грамматические связи и согласования между токенами внутри исходной или целевой последовательности, обеспечивая тем самым корректную генерацию текста. Это гарантирует соблюдение грамматических норм, таких как согласованность слов в роде, числе и падеже.

Вернемся к примеру из предыдущего раздела и исследуем работу self-attention в RNN-энкодере и RNN-декодере переводчика текста с английского языка на русский.

3.3.1 Self – Attention. Encoder

Рассмотрим принцип работы механизма в энкодере.

1) Сначала исходная последовательность подается на RNN токеном за токеном также, как это делалось ранее (рисунок 19). Рекуррентная сеть в это время обновляет свои векторы скрытого состояния h_{et} .




Рисунок 19 – Подаем source-последовательность в энкодер [19]

2) Далее начинает работать self-attention.

На вход функции внимания подается скрытое состояние h_{e0} первого слова «The» и скрытые состояния других слов (рисунок 20). В рассматриваемом примере в source-последовательности пять токенов, поэтому self-attention функций будет четыре.




Рисунок 20 – Пример работы механизма self-attention в задаче машинного перевода [19]

3) По результатам вычисления функции для каждого состояния энкодера на выходе будет некоторое значение – score.

4) Далее, получаем распределение вероятностей на слова в исходном предложении, в результате применения функции активации *softmax* к полученным ранее значениям. Распределение вероятностей выражает то, насколько важно то или иное слово в source-предложении, при обработке первого слова «The» (например, насколько важно при обработке «The» обратить внимание на слово «cat» или на слово «is»).

5) Затем, на основе полученных вероятностей w_i и скрытых состояний энкодера, вычисляется вектор контекста c (выражение 1.10).

6) Обновляем вектор скрытого состояния слова «The», с применением рассчитанного ранее вектора контекста c и своего же предыдущего вектора h_{e0} (рисунок 21).




Рисунок 21 – Обновление вектора скрытого состояния слова «The», в результате работы self-attention [19]

7) Повторяем шаги 2-6 для остальных слов в исходном предложении.

8) В итоге, векторы скрытых состояний в каждый момент времени в энкодере обновились (рисунок 22).




Рисунок 22 – Обновление векторов h_{et} [19]

В результате, применение self-attention позволило скрытым состояниям слов обновить информацию о себе, «посмотреть» на другие слова в предложении и получить более полную информацию о себе в контексте слов вокруг.

3.3.2 Self – Attention. Decoder

Принцип работы self-attention в декодере аналогичен. Единственное отличие – каждый раз, при обновлении скрытых состояний декодера должны учитываться только те слова, которые уже были переведены к текущему моменту времени. Слова «в будущем», которые еще не были переведены на target-язык, не должны обрабатываться механизмом внимания.

На рисунке 23 уже переведены два слова $\langle bos \rangle$ и «кошка». На вход функции self-attention подается скрытое состояние h_{d2} и скрытые состояния других, уже переведенных ранее слов h_{d0} и h_{d1} . В результате применения функции активации softmax к выходам self-attention, получаем значения,

характеризующие важность $\langle \text{bos} \rangle$ и «кошка» при генерации слова «милая». Затем вычисляется контекстный вектор c и обновляется скрытое состояние декодера для слова «милая». Следующее слово будет переводиться уже исходя из обновленного вектора h_{d2} .




Рисунок 23 – Обновление вектора скрытого состояния слова «милая», в результате работы self-attention [19]

3.4 Multi-head attention

Смысл конкретного слова внутри контекста может определяться несколькими связями с другими словами, и эти связи могут быть совершенно разной природы. Поэтому было бы логично иметь не по одной функции self-attention и attention, а по несколько. Причем разные функции будут обращать внимание на разные связи между токенами и в сумме будут добавлять больше информации в каждый эмбединг [21].

Разные головы внимания выделяют как определенную информацию о согласовании слов по падежу, лицу, роду, так и абстрактную. Такая

информация может быть неочевидна для человека, однако полезна для самой модели.

Все головы никак не связаны между собой внутри модели и обучаются независимо друг от друга.

Так, self-attention, который отвечает за согласование слов по роду, будет выдавать большую вероятность связи для двух слов, если они действительно согласуются по роду, и меньшую вероятность в обратном случае.

Выражение для multi-head attention:

$$Multi - head\ attention = concat(attn_1, attn_2, \dots, attn_8) \cdot W \quad (3.12)$$

Резюмируя:

1) Механизм внимания позволяет модели не помнить слишком много информации.

2) Функций внимания может быть много, и тогда каждая из них отвечает за определенную связь между токенами.

3) Attention – это универсальная идея, которая может быть применена во многих задачах машинного обучения, в частности, в задаче генерации текстовых описаний изображения.

3.5 Transformer

Вспомним недостатки RNN:

1) Энкодер на основе RNN очень медленный:

- прямой проход занимает много времени, т.к. обрабатывает входящие токены последовательно;

- обратный проход также отнимает большое количество времени, т.к. происходит распространение градиентов сквозь время.

2) Во время обучения могут возникать проблемы в виде либо затухания, либо взрыва градиентов.

3) RNN сети плохо работают на видеокарте.

Кажется, что теперь, с появлением Attention, можно не хранить всю информацию из исходной последовательности в одном векторе. Следовательно, нужен новый подход для работы с последовательностями.

В 2017 году в статье «Attention is all you need» [20] была предложена новая архитектура на основе механизма внимания – Transformer (рисунок 24). Эта модель также имеет тип Encoder-Decoder.




Рисунок 24 – Архитектура Transformer [20]

При этом роль энкодера и декодера та же: первый из них обрабатывает входную последовательность, а второй генерирует текст токен за токеном, благодаря полученной информации от первого.

Также стоит отметить, что информация на выходе энкодера представлена не одним вектором, как в рекуррентных сетях, а несколькими.

3.5.1 Transformer Encoder

Исследуем принцип работы обработчика входной последовательности в трансформере слой за слоем (рисунок 25).




Рисунок 25 – Архитектура Transformer Encoder [20]

Первый слой – слой эмбеддингов.

Принимает на вход токены и выдает их эмбеддинги. Заметим, что слой обрабатывает все входящие токены параллельно.

Второй слой – Self-attention.

На этом уровне вычисляется вектор внимания для каждого токена, учитывающий полезную информацию из контекста (т.е. из эмбеддингов других токенов), в котором он находится.

Выражение для веса («важности») каждого токена x_i из контекста длины N для, например, первого токена x_1 примет вид:

$$w_{1i} = s(x_1, x_i) \quad (3.13)$$

где $s(x_1, x_i)$ – функция внимания, x_1 и x_i – векторы эмбеддингов, $i \in [1, N]$.

Тогда выражение для вектора внимания a_1 первого токена примет вид:

$$a_1 = \sum_{i=1}^N \blacksquare w_{1i} \cdot x_i \quad (3.14)$$

По такому же алгоритму вычисляются векторы внимания для остальных эмбеддингов в source-последовательности (рисунок 26).




Рисунок 26 – Слой Self-attention [22]

Третий слой – Add (слой сложения).

После того, как вычислены все векторы внимания a_i для входных эмбеддингов x_i , необходимо их суммировать между собой. В результате получим обновленный эмбеддинг x_i (рисунок 27).

$$x_i = x_i + a_i \quad (3.15)$$

Четвертый слой – Layer Norm (слой нормализации).

Нормализация делает обучение более стабильным и помогает избежать взрывающихся градиентов.

На этом шаге считается среднее значение (3.16) и стандартное отклонение (3.17) по всем координатам каждого эмбеддинга:

$$\mu_i = \frac{1}{emb_size} \cdot \sum_{j=1}^{emb_size} \blacksquare x_j^i \quad (3.16)$$

$$\sigma_i = \sqrt{\frac{1}{emb_size} \cdot \sum_{j=1}^{emb_size} \blacksquare (x_j^i - \mu_i)^2} \quad (3.17)$$

где x_j^i – j -ая координата i -го эмбеддинга x , emb_size – размер эмбеддинга.

Далее обновляем каждый вектор x_i :

$$x_i = \frac{x_i - \mu_i}{\sigma_i + \varepsilon} \cdot \gamma + \beta \quad (3.18)$$

где μ_i – среднее значение, σ_i – стандартное отклонение, ε – любое малое значение, γ и β – обучаемые параметры (одинаковы для всех x_i в source-последовательности).




Рисунок 27 – Слой Add&Norm [22]

Пятый слой.

В статье «Attention is all you need» – это два полносвязных слоя с функцией активации `relu` между ними. Хотя в целом, структура может быть любой.

Отметим, что `fully connected` слой применяется к каждому эмбедингу независимо. При этом вход и выход имеют один и тот же размер `emb_size`.

$$x_i = fc(x_i) \quad (3.19)$$

Шестой слой – Add & Norm.

После FC-слоя также идет Add & Norm, аналогичный тому, что был ранее.

Итоговая архитектура энкодера трансформера приведена на рисунке 28.




Рисунок 28 – Детализированная архитектура Encoder-блока трансформера [22]

Резюмируя:

- 1) Результат работы блока Encoder – обновленные эмбединги токенов.
- 2) Каждый слой обрабатывает эмбединги параллельно;
- 3) Каждый слой обрабатывает эмбединги независимо (кроме self-attention);
- 4) Transformer Encoder может обрабатывать последовательности разной длины одинаково хорошо.
- 5) Слои в энкодере можно менять местами.
- 6) Применительно к решаемой в работе задаче генерации текстового описания, принцип работы данного блока будет тем же. Единственная разница

заключается в том, что вместо эмбеддингов токенов на вход будут подаваться векторы признаков изображения, полученные из сверточной нейронной сети.

3.5.2 Positional Encoding

Так как эмбеддинги всех входящих токенов обрабатываются параллельно, сеть не получает информацию о порядке их следования в последовательности. Но эта информация важна для понимания смысла как самих токенов, так всего предложения.

Отсюда следует необходимость добавления информации о положении в входные эмбеддинги.

В статье «Attention is all you need» [20] предложен способ, согласно которому входные векторы x_t должны поэлементно суммироваться с позиционным вектором p_t . Элементы позиционного вектора рассчитываются по следующим формулам:

$$p_{ti} = \left\{ \sin \left(\frac{t}{10000^{\frac{2 \cdot i}{emb_dim}}} \right) \cos \left(\frac{t}{10000^{\frac{2 \cdot i}{emb_dim}}} \right) \right. \quad (3.20)$$




Рисунок 29 – Позиционный вектор p_t

Такой вид функции позиционного кодирования (3.20) порождает такие позиционные векторы p_t , что скалярное произведение двух таких векторов начинает отражать то, насколько далеко друг от друга находятся соответствующие им токены в предложении. В блоке энкодера скалярное произведение векторов происходит в механизме внимания.

Таким образом, благодаря позиционному кодированию, attention будет получать информацию об относительном положении эмбеддингов внутри последовательности во время обучения модели.

3.5.3 Transformer Decoder

Блок декодера также принимает на вход набор эмбеддингов.

Исследуем работу декодера слой за слоем (рисунок 30).




Рисунок 30 – Архитектура Transformer Decoder [20]

Первый слой – Masked Self-attention.

Последовательность преобразований для целевых эмбеддингов при этом примерно та же, что и в энкодере. Единственное отличие – во время обучения векторы внимания декодера a_i не должны брать информацию из «будущих» токенов. То есть требуется смоделировать ситуацию, в которой декодер

генерирует выходное предложение, и при получении каждого следующего токена он ничего не знает о тех токенах, которые должны быть дальше («в будущем»).

Получается, что в слое self-attention связи, отмеченные красным, не должны быть разрешены. Решение: просто удалим их (рисунок 31).




Рисунок 31 – Masked self-attention [23]

Таким образом, каждый вектор внимания a_i будет учитывать только «прошлые» (левые) эмбединги, без учета «будущих» (правых).

Второй слой – Add&Norm.

Принцип работы данного слоя такой же, как и в энкодере.

Третий слой – Multi-head attention.

Часто это слой называют Cross-attention – это простой механизм внимания (не self-attention) между эмбедингами энкодера и декодера.

Принцип работы точно такой же, как и в attention в RNN сети: каждый эмбединг декодера $x_1^d, x_2^d, x_3^d, \dots, x_m^d$ должен обновить информацию о себе, обратив внимание на каждый эмбединг энкодера $x_1^e, x_2^e, x_3^e, \dots, x_n^e$.

Визуализация Cross-attention приведена на рисунке 32.




Рисунок 32 – Cross-Attention [23]

Этот слой – единственное место, где декодер трансформера получает информацию из энкодера.

Принцип работы остальных слоев декодера совпадает с рассмотренными ранее.

Итоговая архитектура энкодера трансформера приведена на рисунке 33.




Рисунок 33 – Детализированная архитектура Decoder-блока трансформера [23]

Отметим, что во время инференса декодер будет генерировать предсказанную им последовательность авторегрессионно, токен за токеном.

Резюмируя:

1. Декодер трансформатора генерирует выходную последовательность по одному токеноу за раз.
2. Каждый слой декодера обрабатывает последовательность токенов параллельно.

3. Каждый слой декодера обрабатывает токены независимо (кроме masked self-attention и cross-attention).

4. Декодер трансформатора может обрабатывать последовательности разной длины одинаково хорошо.

5. Слои в декодере можно менять местами.

6. Применительно к решаемой в работе задаче генерации текстового описания, принцип работы декодера трансформатора будет тем же: на вход будут подаваться эмбединги токенов целевого описания изображения.

3.6 Вывод

В рамках данного раздела был проведен обзор двух основных подходов к моделированию языковой компоненты в задаче генерации описания изображения – на базе рекуррентных нейронных сетей (LSTM) и трансформерных архитектур.

LSTM-модели являются одним из наиболее распространенных решений для генерации текста, благодаря их способности эффективно моделировать последовательные данные и долгосрочные зависимости.

В противовес LSTM, архитектура Transformer базируется исключительно на механизме внимания, без использования рекуррентных связей. Механизм внимания позволяет модели динамически фокусироваться на наиболее релевантных частях входной последовательности (в данном случае, визуальных признаков) при генерации каждого выходного токена. Это дает Transformer большую гибкость и параллелизацию по сравнению с рекуррентными подходами.

4 Метрики

В качестве метрик оценки качества генерации описания использовались BLEU, BERT score и визуальная оценка.

4.1 BLEU

Самая распространенная метрика качества – BLEU (Bilingual Evaluation Understudy).

BLEU считает точность по N-граммам.

Пример расчета BLEU в задаче машинного перевода:

Исходное предложение: кошка сидит.

Целевое предложение: the cat is sitting.

Сгенерированное предложение: the the cat.

Таблица 1 – Пример расчета BLEU

	N-граммы	Точность
Униграммы	the, the, cat	$\frac{(1 + 1 + 1)}{3} = 1$
Биграммы	the the, the cat	$\frac{(0 + 1)}{2} = 0,5$
Триграммы	the the cat	$\frac{0}{1} = 0$

Итоговое значение BLEU для примера будет равно: $1 + 0,5 + 0 = 1,5$.

Очевидно, чем больше BLEU, тем лучше.

4.2 BERT score

BERT Score – это метрика, которая вычисляет степень сходства для каждой лексемы в предложении-кандидате с каждой лексемой в эталонном предложении. Она использует предварительно обученные эмбединги из модели BERT и сопоставляет слова в предложениях-кандидатах и эталонных предложениях по косинусному сходству.

Кроме того, BERT Score вычисляет precision, recall, и F1, что может быть полезно для оценки сгенерированного текста.




Рисунок 34 – Принцип работы BERT score [24]

5 Датасет

Для обучения моделей для задачи Image Captioning использовался датасет MS COCO Captions 2017 [25].

Каждый пример в этом наборе данных представляет из себя изображение и минимум пять описаний к нему.

Всего в обучающей выборке 118 тысяч изображений, а валидационной – 5 тысяч изображений.

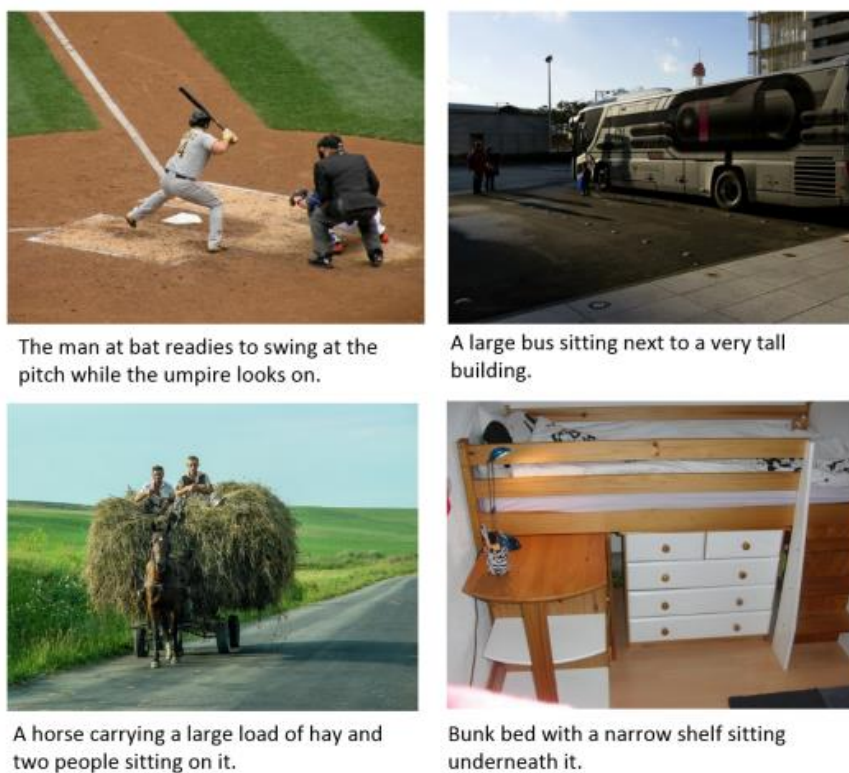


Рисунок 35 – Примеры изображений и их описаний в датасете MS COCO Captions [26]

6 Результаты применения нейросетевых алгоритмов для генерации текстовых описаний изображений

В рамках данной работы были проведены эксперименты по применению нейросетевых алгоритмов для решения задачи генерации описаний изображений.

В ходе экспериментов было исследовано качество нескольких подходов к генерации текстовых описаний, которое оценивалось по упомянутым ранее метрикам. Также было учтено время обучения моделей, для сравнения их эффективности.

Полученные результаты и выводы, сделанные в ходе этих экспериментов, позволят глубже понять возможности и ограничения существующих методов, а также обозначить перспективные направления для дальнейших исследований в данной области. Анализ результатов представлен далее.

6.1 Эксперимент №1

Описание: в рамках данного эксперимента была произведена сравнительная оценка трех различных подходов к генерации текстовых описаний изображений длиной в восемь, двенадцать и шестнадцать токенов. Ключевой особенностью данного сравнения является использование одной и той же модели компьютерного зрения (VGG16) в качестве визуального экстрактора признаков, в то время как для обработки текстовой информации применялись три различные архитектуры: LSTM, Transformer Decoder, Transformer.

Тестируемые модели:

1. VGG16 + LSTM;
2. VGG16 + Transformer Decoder;
3. VGG16 + Transformer.

Цель эксперимента: сравнить текстовые декодеры модели (LSTM, Transformer Decoder и Transformer) по качеству генерации текстовых описаний длиной 8, 12 и 16 токенов.

Результаты

1) Длина описания 8 токенов

По результатам обучения видим (таблица 2), что наилучшие показатели у модели, где в роли декодера используется Transformer Decoder. Модификация VGG16 + Transformer Decoder превосходит аналоги по всем метрикам BLEU и по BERT score, при этом имеет наименьшее время обучения – всего 10 минут, и наименьшую ошибку – 0,385. Стоит также отметить, что обучение сети VGG16+LSTM заняло в 2,5 раз больше времени, при худших показателях метрик.

Таблица 2 – Метрики моделей по генерации описаний длиной 8 токенов

Метрики	VGG16+LSTM	VGG16 + Transformer Decoder	VGG16 + Transformer
Val loss	2,543	0,385	0,664
BLEU 1	70,0	94,7	86,9
BLEU 2	56,1	93,3	83,1
BLEU 3	47,5	92,4	80,6
BLEU 4	41,8	91,6	78,5
BERT Precision	0,887	0,982	0,955
BERT Recall	0,888	0,98	0,951
BERT F1	0,887	0,981	0,953
Количество эпох	5	40	40
Время обучения, мин	25	10	11

По динамике изменения метрик видим, что модель VGG16+LSTM переобучилась на четвертой и пятой эпохах, но BLEU при этом продолжил увеличиваться. BERT score для данной модели также начал уменьшаться на пятой эпохе (см. Приложение Б).

Для моделей VGG16 + Transformer Decoder и VGG16 + Transformer loss на валидационной выборке стремился к нулю в течение всего времени обучения, а BLEU и BERT score стремились к своим максимальным значениям.

При визуальном сравнении качества генерации описаний, видим, что все три модели справились с этой задачей примерно одинаково – каждая модель смогла распознать ключевые объекты изображения и совершаемые ими действия (см. Приложение Б).

2) Длина описания 12 токенов

По результатам обучения видим (таблица 3), что наилучшие показатели у модели, где в роли декодера используется Transformer Decoder. Модификация VGG16 + Transformer Decoder превосходит аналоги по всем метрикам BLEU и по BERT score, при этом имеет наименьшее время обучения – всего 14 минут, и наименьшую ошибку – 0,794. Стоит также отметить, что обучение сети VGG16+LSTM заняло примерно в 4 раза больше времени, при худших показателях метрик.

Таблица 3 – Метрики моделей по генерации описаний длиной 12 токенов

Метрики	VGG16+LSTM	VGG16 + Transformer Decoder	VGG16 + Transformer
Val loss	2,662	0,794	1,347
BLEU 1	73,9	87,9	81,0
BLEU 2	59,8	83,7	73,1
BLEU 3	50,7	81,0	68,0
BLEU 4	44,5	78,8	64,2
BERT Precision	0,888	0,952	0,926
BERT Recall	0,892	0,949	0,923
BERT F1	0,89	0,951	0,925
Количество эпох	5	40	40
Время обучения, мин	61	14	16

По динамике изменения метрик видим, что модель VGG16+LSTM также переобучилась на четвертой и пятой эпохах, но BLEU и BERT score при этом продолжили увеличиваться (см. Приложение В).

Для моделей VGG16 + Transformer Decoder и VGG16 + Transformer validation loss стремился к нулю в течение всего времени обучения, а BLEU и BERT score стремились к своим максимальным значениям.

При визуальном сравнении качества генерации описаний, видим, что все три модели распознали ключевые объекты изображения, совершаемые ими действия, а также среду окружения объектов. Отметим, что описания VGG16+LSTM выглядят более естественными и логически завершенными (см. Приложение В).

3) Длина описания 16 токенов

По результатам обучения видим (таблица 4), что наилучшие показатели у той же модели, где в роли декодера используется Transformer Decoder. Модификация VGG16 + Transformer Decoder превосходит аналоги по всем метрикам BLEU и по BERT score, при этом имеет наименьшее время обучения – 17 минут, и наименьшую ошибку – 1,005.

Таблица 4 – Метрики моделей по генерации описаний длиной 16 токенов

Метрики	VGG16+LSTM	VGG16 + Transformer Decoder	VGG16 + Transformer
Val loss	2,661	1,005	1,264
BLEU 1	74,3	84,3	82,2
BLEU 2	60,1	78,6	74,4
BLEU 3	50,7	74,8	69,2
BLEU 4	44,3	71,8	65,4
BERT Precision	0,878	0,931	0,922
BERT Recall	0,895	0,936	0,927
BERT F1	0,887	0,933	0,924
Количество эпох	5	40	40
Время обучения, мин	48	17	22

По динамике изменения метрик видим, что модель VGG16+LSTM также переобучилась на четвертой и пятой эпохах, но BLEU и BERT score при этом продолжили увеличиваться (см. Приложение Г).

Для моделей VGG16 + Transformer Decoder и VGG16 + Transformer validation loss стремился к нулю в течение всего времени обучения, а BLEU и BERT score стремились к своим максимальным значениям.

При визуальном сравнении качества генерации описаний, видим, что все три модели распознали ключевые объекты изображения, совершаемые ими действия, а также среду окружения объектов. Стоит отметить, что описания VGG16+LSTM выглядят более естественными и логически завершенными. В то же время у описаний, сгенерированных трансформерами моделями, нередко встречается дублирование слов и оборотов (см. Приложение Г).

Вывод

Сравнительный анализ результатов экспериментов позволил выявить ключевые особенности и различия между рассматриваемыми подходами. Модели, декодеры которых используют механизм внимания, продемонстрировали преимущество в показателях метрик обучения во всех проведенных тестах.

В то же время, опираясь на визуальную оценку качества генерации, все три модели смогли распознать ключевые объекты на изображении, а также действия совершаемые ими и детали окружающей среды. При этом, описания LSTM-based модели выглядят более содержательными и грамматически правильными по сравнению с Transformer-based декодерами, в которых могут встречаться повторяющиеся слова и обороты.

Время обучения LSTM-based модели значительно превышало время обучения Transformer-based моделей (VGG16 + Transformer Decoder, VGG16 + Transformer) при сравнении на текстовых описаниях одинаковой длины (8, 12 и 16 токенов). Причем с увеличением длины описания время обучения LSTM-модели возрастало кратно сильнее, чем у Transformer-based моделей.

Данное наблюдение свидетельствует о существенном преимуществе Transformer-based архитектур в плане вычислительной эффективности и масштабируемости при решении задачи генерации текстовых описаний изображений.

В совокупности, лучшая модель – VGG16 + Transformer Decoder.

6.2 Эксперимент №2

Описание: в рамках данного эксперимента была произведена сравнительная оценка трех различных подходов к генерации текстовых описаний изображений длиной 12 токенов. Ключевой особенностью данного сравнения является использование трех различных моделей компьютерного зрения в качестве визуальных экстракторов признаков, в то время как для обработки текстовой информации применялся Transformer Decoder.

Тестируемые модели:

1. Efficientnet_v2_s + Transformer Decoder;
2. VGG16 + Transformer Decoder;
3. ResNet18 + Transformer Decoder.

Цель эксперимента: сравнить модели компьютерного зрения (Efficientnet_v2_s, VGG16 и ResNet18) по влиянию на качество генерации текстовых описаний длиной 12 токенов.

Результаты

По результатам обучения видим (таблица 5), что наилучшие показатели у модели, где в роли энкодера используется сеть VGG16. Модификация VGG16 + Transformer Decoder превосходит аналоги по всем метрикам BLEU и по BERT score. При этом время обучения и количество эпох у всех сетей одинаковое – 14 минут и 40 эпох.

Таблица 5 – Метрики моделей по генерации описаний длиной 12 токенов

Метрики	Efficientnet_v2_s + Transformer Decoder	VGG16 + Transformer Decoder	ResNet18 + Transformer Decoder
Val loss	1,669	0,794	1,894
BLEU 1	77,5	87,9	75,5
BLEU 2	67,4	83,7	64,3
BLEU 3	60,7	81,0	56,7
BLEU 4	56,0	78,8	51,4
BERT Precision	0,909	0,952	0,9
BERT Recall	0,909	0,949	0,901
BERT F1	0,909	0,951	0,9
Количество эпох	40	40	40
Время обучения, мин	14	14	13,9

При визуальном сравнении качества генерации описаний, видим, что модель VGG16 + Transformer Decoder справилась лучше всего. Она, в отличие от двух других архитектур, распознает объекты, действия и предметы окружающей среды, а также генерирует намного более естественный текст. В это же время, модели с энкодерами в виде Efficientnet_v2_s и ResNet18 не смогли даже распознать, что изображено на изображении (см. Приложение Д).

Вывод

Результаты эксперимента показывают, что модель на основе VGG16 в сочетании с Transformer Decoder демонстрирует наиболее высокие показатели качества генерации текстовых описаний, ввиду большего количества параметров (VGG16 - 138 млн, EfficientNet V2 - 24 млн, ResNet18 - 10 млн).

Модификация VGG16 + Transformer Decoder превзошла аналогичные модели с EfficientNet V2 и ResNet18 по всем метрикам BLEU и BERT score.

При этом время обучения и количество эпох были одинаковыми для всех архитектур.

Качественный анализ сгенерированных описаний также подтверждает преимущество VGG16 + Transformer Decoder. Эта модель успешно распознает объекты, действия и окружение на изображениях, в отличие от других архитектур, которые демонстрируют более низкое качество описаний.

Данные результаты указывают на то, что, несмотря на более компактную структуру и меньшее количество параметров у EfficientNet V2 и ResNet18, VGG16 остается более эффективной визуальной моделью для задачи генерации текстовых описаний изображений в сочетании с Transformer Decoder. Это может быть связано с более богатым представлением визуальных признаков, которое способна извлечь VGG16.

6.3 Эксперимент №3

Описание: в рамках данного эксперимента была произведена сравнительная оценка трех различных подходов к генерации текстовых описаний изображений длиной 12 токенов. Ключевой особенностью данного сравнения является использование разного количества голов внимания (8, 16 и 64) в модели Transformer Decoder.

Тестируемые модели: VGG16 + Transformer Decoder;

Цель эксперимента: исследовать влияние количества голов внимания в модели Transformer Decoder на качество генерации текстовых описаний изображений длиной 12 токенов.

Результаты

По результатам обучения видим (таблица 6), что во всех трех случаях метрики почти одинаковы. При этом время в случае с $n_head = 64$ почти на 4 минуты больше.

Таблица 6 – Метрики модели VGG16 + Transformer Decoder по генерации описаний длиной 12 токенов

Метрики	n_head = 8	n_head = 16	n_head = 64
Val loss	1.238	1.194	1.152
BLEU 1	79.9	80.5	81.8
BLEU 2	73.3	74.0	75.6
BLEU 3	68.89	69.7	71.5
BLEU 4	65.5	66.3	68.2
BERT Precision	0.925	0.926	0.93
BERT Recall	0.922	0.923	0.927
BERT F1	0.923	0.925	0.929
Количество эпох	40	40	40
Время обучения, мин	13.36	13.41	17.16

При визуальном сравнении качества генерации описаний, видим, что весомого отличия в лучшую или худшую сторону нет ни у одной из моделей (см. Приложение Е).

Вывод

Анализ результатов показывает, что на длине текстовых описаний в 12 токенов, изменение количества голов внимания (8, 16, 64) в модели Transformer Decoder не оказывает существенного влияния на качество генерируемых описаний.

Во-первых, метрики качества, такие как BLEU и BERT score, демонстрируют практически идентичные значения для всех трех вариантов моделей. Это свидетельствует об отсутствии значимых различий в объективных показателях качества генерируемых текстовых описаний.

Во-вторых, визуальное сравнение сгенерированных описаний не выявило явных преимуществ или недостатков какой-либо из моделей. Все три

варианта Transformer Decoder показали сопоставимое качество и адекватность генерируемых текстов.

Однако стоит отметить, что время обучения модели с 64 головами внимания оказалось на 4 минуты дольше, чем у моделей с 8 и 16 головами. Это указывает на более высокую вычислительную сложность данной модификации, что может быть важным практическим соображением при выборе архитектуры.

Таким образом, при выборе количества голов, стоит опираться в первую очередь на длину генерируемого текста.

6.4 Вывод

В ходе проведенных экспериментов была исследована эффективность различных подходов к построению моделей для задачи Image Captioning. Всего было реализовано и сравнено девять архитектур.

Результаты экспериментов показали, что наилучшие показатели по метрикам BLEU, BERT score и визуальной оценке были достигнуты моделью, использующей VGG16 в качестве визуального энкодера и Transformer Decoder с 8 головами внимания.

Данная архитектура продемонстрировала способность генерировать наиболее содержательные, связные и релевантные описания изображений по сравнению с другими рассмотренными подходами, при наименьшем времени обучения.

ЗАДАНИЕ ДЛЯ РАЗДЕЛА «ФИНАНСОВЫЙ МЕНЕДЖМЕНТ, РЕСУРСОЭФФЕКТИВНОСТЬ И РЕСУРСОСБЕРЕЖЕНИЕ»

Студенту:

Группа	ФИО
8BM22	Ямкину Никите Николаевичу

Школа	ИШИТР	Отделение школы (НОЦ)	ОИТ
Уровень образования	магистратура	Направление/специальность	09.04.01 «Информатика и вычислительная техника»

Исходные данные к разделу «Финансовый менеджмент, ресурсоэффективность и ресурсосбережение»:

1. Стоимость ресурсов научного исследования (НИ): материально-технических, энергетических, финансовых, информационных и человеческих	Бюджет проекта – не более 300 000 руб., в т.ч. затраты по оплате труда – не более 150 000 руб.
2. Нормы и нормативы расходования ресурсов	Районный коэффициент 30%; Коэффициент дополнительной заработной платы 15%; Накладные расходы 20%
3. Используемая система налогообложения, ставки налогов, отчислений, дисконтирования и кредитования	Коэффициент отчислений на уплату во внебюджетные фонды 30%

Перечень вопросов, подлежащих исследованию, проектированию и разработке:

1. Оценка коммерческого и инновационного потенциала НТИ	- Анализ конкурентных технических решений
2. Планирование процесса управления НТИ: структура и график проведения, бюджет, риски и организация закупок	Формирование плана и графика разработки: - определение структуры работ; - определение трудоемкости работ; - разработка графика Ганта. Формирование бюджета затрат на научное исследование: - заработная плата (основная и дополнительная); - отчисления на социальные цели; - накладные расходы.
3. Определение ресурсной, финансовой, экономической эффективности	- Определение потенциального эффекта исследования

Перечень графического материала (с точным указанием обязательных чертежей):

1. «Портрет» потребителя результатов НТИ
2. Оценка конкурентоспособности технических решений
3. Матрица SWOT
4. График проведения и бюджет НТИ
5. Оценка ресурсной, финансовой и экономической эффективности НТИ

Дата выдачи задания для раздела по линейному графику	
--	--

Задание выдал консультант:

Должность	ФИО	Ученая степень, звание	Подпись	Дата
Профессор БШ	Жиронкин Сергей Александрович	Д.э.н.		

Задание принял к исполнению студент:

Группа	ФИО	Подпись	Дата
8BM22	Ямкин Никита Николаевич		

7 Финансовый менеджмент, ресурсоэффективность и ресурсосбережение

7.1 Предпроектный анализ

7.1.1 Потенциальные потребители результатов исследования

В рамках магистерской диссертации разрабатывается три разных модификации алгоритма генерации текстового описания изображения на основе нейросетевых архитектур.

Каждый из этих алгоритмов создает возможность поиска конкретных изображений или видео на основе их визуального содержания. Это позволяет быстро находить нужные фотографии, иллюстрации, видеоролики в крупных базах данных и систематизировать их по содержанию. В результате этого можно значительно оптимизировать по времени все бизнес-процессы, связанные управлением и обработкой медиафайлов.

Потенциальными потребителями разработки могут стать крупные компании-владельцы социальных сетей (например VK), средства массовой информации и прочие предприятия, чьи бизнес-процессы связаны с большим количеством медиа-данных.

Алгоритмы также могут быть использованы научно-исследовательскими институтами, университетами и проектными организациями для создания комплексного продукта или для исследований.

7.1.2 Анализ конкурентных технических решений с позиции ресурсоэффективности и ресурсосбережения

Оценим конкурентоспособность каждого из разработанных алгоритмов. Примем, VGG16 + LSTM – $B_{к1}$, VGG16 + Transformer Decoder – $B_{к2}$, а VGG16 + Transformer – $B_{к3}$.

Таблица 7 – Оценочная карта технического решения

Критерии оценки	Вес критерия	Баллы			Конкурентоспособность		
		$B_{к1}$	$B_{к2}$	$B_{к3}$	$K_{к1}$	$K_{к2}$	$K_{к3}$
1	2	3	4	5	6	7	8
Технические критерии оценки ресурсоэффективности							
1. Метрики описания изображения (BLEU, BERT Score)	0,2	2	5	4	0,4	1	0,8
2. Скорость обучения (время на эпоху)	0,08	2	5	5	0,16	0,4	0,4
3. Время генерации подписи (инференс)	0,02	5	5	5	0,1	0,1	0,1
4. Размер модели (количество параметров)	0,02	5	4	3	0,1	0,08	0,06
5. Требуемый объём данных для обучения	0,08	5	5	5	0,4	0,4	0,4
6. Обобщающая способность на тестовых данных	0,08	4	4	4	0,32	0,32	0,32
7. Устойчивость к шуму/искажениям на изображении	0,08	3	4	4	0,24	0,32	0,32
8. Интерпретируемость и объяснимость модели	0,04	3	4	3	0,12	0,16	0,12
9. Вычислительная эффективность на GPU	0,04	1	5	5	0,04	0,2	0,2
10. Возможность переноса на другие задачи (transfer learning)	0,02	2	3	3	0,04	0,06	0,06

Продолжение таблицы 7

Экономические критерии оценки ресурсоэффективности							
1. Стоимость разработки и внедрения	0,1	3	4	3	0,3	0,3	0,3
2. Эксплуатационные расходы (аппаратные, энергопотребление)	0,04	2	3	3	0,08	0,12	0,12
3. Масштабируемость	0,05	2	3	3	0,1	0,15	0,15
4. Потенциал коммерциализации и монетизации	0,1	3	5	4	0,3	0,4	0,4
5. Соответствие регуляторным требованиям (безопасность, этичность)	0,05	5	5	5	0,25	0,25	0,25
ИТОГО	1	47	64	59	2,95	4,26	4

Позиция разработки и конкурентов оценивается по каждому показателю экспертным путем по пятибалльной шкале, где 1 – наиболее слабая позиция, а 5 – наиболее сильная. Веса показателей, определяемые экспертным путем, в сумме должны составлять 1.

Анализ конкурентных технических решений определяется по формуле:

$$K = \sum_{i=1}^n B_i B_i \quad (7.1)$$

где K – конкурентоспособность научной разработки или конкурента;

B_i – вес показателя (в доля единицы);

B_i – балл i -го показателя.

Исходя из проведенного анализа конкурентоспособности, можно выделить алгоритмы VGG16 + Transformer Decoder и VGG16 + Transformer, как наиболее перспективные. Оба алгоритма обладают преимуществами благодаря использованию механизма внимания, что значительно повышает их эффективность.

Однако следует отметить, что в архитектуре Transformer Decoder меньше параметров, чем в Transformer, что делает её более быстрой.

7.1.3 SWOT-анализ

SWOT-анализ дает возможность оценить сильные и слабые стороны, возможности и угрозы проекта методом стратегического планирования.

Таблица 8 – SWOT-анализ проекта

	Внутренние факторы		
		Сильные стороны проекта:	Слабые стороны проекта:
		С1. Проект востребован С2. Аналогов очень мало С3. Много отраслей для применения	Сл1. Сложность разработки Сл2. Тестирование занимает много времени Сл3. Необходим высококвалифицированный персонал
	Внешние факторы	Возможности: В1. Развитие информационных технологий В2. Развитие вычислительных систем	Проект востребован, а конкуренции мало. Существует огромный рынок для применения технологии.
	Угрозы: У1. Захват рынка конкурентами У2. Повышение цен на компьютерное оборудование	Время на тестирование и потребности в вычислительных ресурсах со временем будут меньше влиять на сложность проекта т.к. развитие информационных технологий, а также вычислительных систем постоянно упрощают решение вычислительных задач.	Востребованность проекта будет привлекать множество конкурентов. Большое количество отраслей служат защитой компании от убытков при повышении цен на комп. оборудование.
		Повышение цен на комп. оборудование может сильно повысить стоимость и время разработок. Цены также растут из-за ослабления курса рубля. Для уменьшения данных рисков можно хранить финансы в долларах(евро), а также закупить оборудования для разработок.	

Из анализа можно сделать вывод, что актуальность данного исследования растёт. Все возможные сдерживающие факторы покрываются быстрым развитием вычислительных систем и информационных технологий, что открывает путь для маленьких и средних производств.

7.2 Планирование научно-исследовательских работ

Данный раздел необходим для планирования будущих работ, оценки каждого участка и определения его продолжительности, а также прогнозирование итоговой продолжительности проекта. При планировании таких работ необходимо оптимально планировать занятость каждого из участников проекта.

7.2.1 Структура работ в рамках научного исследования

Процесс проведения работ в рамках научного исследования имеет определённую структуру и может быть разбит на этапы, которые включают в себя список работ и их исполнителей. Перечень этапов, работ и распределение исполнителей приведены ниже, таблица 9.

Таблица 9 – Перечень этапов, работ и распределение исполнителей

№ работы	Наименование работы	Исполнители работы
1	Выбор научного руководителя ВКР	Ямкин Н.Н.
2	Составление и утверждение темы ВКР	Спицын В.Г. Ямкин Н.Н.
3	Составление календарного плана-графика выполнения ВКР	Спицын В.Г.
4	Подбор и изучение литературы по теме ВКР	Ямкин Н.Н.
5	Анализ предметной области	Ямкин Н.Н.
6	Проектирование структуры моделей	Ямкин Н.Н.
7	Программирование спроектированных моделей	Ямкин Н.Н.
8	Тестирование запрограммированных моделей	Ямкин Н.Н.
9	Анализ результатов	Ямкин Н.Н.
10	Согласование выполненной работы с научным руководителем	Спицын В.Г. Ямкин Н.Н.
11	Выполнение других частей работы (финансовый менеджмент, социальная ответственность)	Ямкин Н.Н.
12	Подведение итогов, оформление работы	Ямкин Н.Н.

7.2.2 Определение трудоемкости выполнения работ

Для определения трудоемкости работ, необходимо оценить минимальное и максимальное затраченное на работу время.

Произведём расчёт ожидаемой трудоемкости это с помощью формулы:

$$t_{ож\ i} = \frac{3t_i + 2t_i}{5} \quad (7.2)$$

Учитывая, что исполнитель один, ускорить работу за счет распараллеливания не предоставляется возможным.

7.2.3 Разработка графика проведения научного исследования

Построим таблицу временных показателей научного исследования. Согласно производственному календарю (для 6-дневной рабочей недели) в 2024 году 366 календарных дней, 300 рабочих дней, 66 выходных/праздничных дней.

Для расчёта длительности работ в календарных днях рассчитаем коэффициент календарности:

$$T_{кал} = \frac{T_{кал}}{T_{кал} - T_{вых} - T_{пр}} = \frac{366}{366 - 66} = 1,22. \quad (7.3)$$

Таблица 10 – Временные показатели научного исследования

Наименование работы	Исполнители работы	Трудоемкость работ, чел-дни			Длительность работ, дни	
		$t_{\min}$	$t_{\max}$	$t_{\text{ож}}$	T_p	T_k
Выбор научного руководителя ВКР	Ямкин Н.Н.	1	2	1,4	1	2
Составление и утверждение темы ВКР	Спицын В.Г.	1	2	1,4	1	1
	Ямкин Н.Н.	1	2	1,4	1	1
Составление календарного плана-графика выполнения ВКР	Спицын В.Г.	1	3	1,8	1	2
Подбор и изучение литературы по теме ВКР	Ямкин Н.Н.	2	5	3,2	3	4
Анализ предметной области	Ямкин Н.Н.	2	5	3,2	3	4
Проектирование структуры моделей	Ямкин Н.Н.	3	6	4,2	4	5
Программирование спроектированных моделей	Ямкин Н.Н.	15	30	21	21	26
Тестирование запрограммированных моделей	Ямкин Н.Н.	20	40	28	28	34
Анализ результатов	Ямкин Н.Н.	5	10	7	7	9
Согласование выполненной работы с научным руководителем	Спицын В.Г.	5	8	6,2	3	4
	Ямкин Н.Н.	5	8	6,2	3	4
Выполнение других частей работы (финансовый менеджмент, социальная ответственность)	Ямкин Н.Н.	5	10	7	7	9
Подведение итогов, оформление работы	Спицын В.Г.	7	10	8,2	4	5
	Ямкин Н.Н.	7	10	8,2	4	5

На основе построенной выше таблицы, построим диаграмму Ганта.




Рисунок 36 – Диаграмма Ганта

7.2.4 Бюджет научно-технического исследования

Затраты на создание проекта состоят из всех расходов необходимых для реализации комплекса работ, составляющих содержание данного исследования. Сметная стоимость формируется по следующим статьям затрат:

- затраты на оборудование;
- амортизационные отчисления;
- основная заработная плата исполнителей проекта;
- дополнительная заработная плата исполнителей проекта;
- социальный налог;
- оплата услуг связи;
- отчисления во внебюджетные фонды (страховые отчисления);
- накладные расходы.

В процессе формирования бюджета, планируемые затраты группируются по статьям.

Расчет затрат на оборудование и его амортизацию

В итоговую стоимость проекта входят отчисления на амортизацию за время использования оборудования в статье накладных расходов.

Расчёт амортизации производится на находящееся в использовании оборудование. При выполнении проекта использовался компьютер, в качестве среды выполнения выступал облачный сервис Jupyter Hub с видеокартой.

Расчет амортизации проводится следующим образом:

Норма амортизации определяется по следующей формуле:

$$H_A = \frac{1}{n}, \quad (7.4)$$

где n – срок полезного использования в годах.

Амортизация определяется по следующей формуле:

$$A = \frac{H_{AI}}{12} \cdot m, \quad (7.5)$$

где И – итоговая сумма, тыс. руб.; т – время использования, мес.

Таблица 11 – Затраты на оборудование

№	Наименование оборудования	Кол-во, шт.	Срок полезного использования, лет	Цены единицы оборудования, тыс. руб.	Общая стоимость оборудования, тыс. руб.
1	Компьютер	1	5	50	50
Итого:		50 тыс. руб.			

Рассчитаем норму амортизации для компьютера, с учетом того, что срок полезного использования составляет 5 лет:

$$H_A = \frac{1}{n} = \frac{1}{5} = 0,2. \quad (7.6)$$

Общую сумму амортизационных отчислений находим следующим образом:

$$A = \frac{H_A \cdot И}{12} \cdot t = \frac{0,2 \cdot 50000}{12} \cdot 4 = 3\,333 \text{ руб.} \quad (7.7)$$

Основная заработная плата исполнителей темы

При разработке ПО основной статьёй расходов является заработная плата специалистов. Поэтому для расчёта расходов на НТИ необходимо посчитать оклад специалистов за время исследования. Расходы определяются по следующей формуле:

$$З_{\Pi} = З_{\text{осн}} + З_{\text{доп}}, \quad (7.8)$$

где $З_{\text{осн}}$ – основная заработная плата, руб.; $З_{\text{доп}}$ – дополнительная заработная плата, руб.

Основная заработная плата высчитывается по формуле:

$$З_{\text{осн}} = З_{\text{дн}} \cdot T_p \cdot k_p, \quad (7.9)$$

где $З_{\text{дн}}$ – среднедневная заработная плата, руб.; T_p – продолжительность работ, выполняемых работником, раб. дни; k_p – районный коэффициент (1,3).

Среднедневная заработная плата высчитывается по формуле:

$$Z_{\text{дн}} = \frac{Z_{\text{м}} \cdot M}{F_{\text{д}}}, \quad (7.10)$$

где $Z_{\text{м}}$ – месячный оклад работника, руб.; M – количество месяцев работы без отпуска в течение года равное 10,4 месяца для шестидневного рабочей недели и 11,2 месяца для пятидневной; $F_{\text{д}}$ – действительный годовой фонд рабочего времени персонала, раб. дн., таблица 12.

Таблица 12 – Баланс рабочего времени

Показатели рабочего времени	Руководитель	Инженер
Календарное число дней	366	366
Количество нерабочих дней	66	118
Потери рабочего времени (отпуск + невыходы по болезни)	56	28
Действительный годовой фонд рабочего времени	244	220

Расчет основной заработной платы приведен ниже, $Z_{\text{осн}}$ рассчитана с учетом районного коэффициента (1,3), таблица 13.

Таблица 13 – Расчет основной заработной платы исполнителей

Исполнитель	$Z_{\text{б}}$, руб.	$k_{\text{р}}$	$Z_{\text{м}}$, руб.	$Z_{\text{дн}}$, руб.	$T_{\text{р}}$, дн.	$Z_{\text{осн}}$, руб.
Руководитель	58 014	1,3	75 418,2	3 214,5	9	28 931
Инженер	21 120	1,3	27 456	1 397,8	82	114 620
Итого по статье $Z_{\text{осн}}$:			143 551			

Дополнительная заработная плата исполнителей темы

Затраты по дополнительной заработной плате исполнителей учитывают величину предусмотренных Трудовым кодексом РФ доплат за отклонение от нормальных условий труда, а также выплат, связанных с обеспечением гарантий и компенсаций (при исполнении государственных и общественных обязанностей, при совмещении работы с обучением, при предоставлении ежегодного оплачиваемого отпуска и т.д.). Дополнительная заработная плата начисляется по формуле:

$$З_{\text{доп}} = З_{\text{осн}} \cdot k_{\text{доп}}, \quad (7.11)$$

где $k_{\text{доп}}$ – коэффициент дополнительной з/п. Принимает его равным 0,15. После расчета дополнительной заработной платы получаем следующие цифры, таблица 14.

Таблица 14 – Дополнительная заработная плата исполнителей

Исполнитель	$З_{\text{осн}}$, руб.	$k_{\text{доп}}$	$З_{\text{доп}}$, руб.
Руководитель	28 931	0,15	4 340
Инженер	114 620	0,15	17 193

Отчисления во внебюджетные фонды

Теперь необходимо рассчитать отчисления во внебюджетные фонды. Они рассчитываются следующим образом:

$$З_{\text{внеб}} = k_{\text{внеб}} \cdot (З_{\text{осн}} + З_{\text{доп}}), \quad (7.12)$$

где $k_{\text{внеб}}$ – коэффициент отчислений на уплату во внебюджетные фонды (пенсионный фонд, фонд обязательного медицинского страхования и пр.). Для образовательных и научных учреждений он составляет 30%. Результат вычислений приведен ниже, таблица 15.

Таблица 15 – Отчисления во внебюджетные фонды

Исполнитель	$З_{\text{осн}}$, руб.	$З_{\text{доп}}$, руб.	$k_{\text{внеб}}$, %	$З_{\text{стр}}$, руб.
Руководитель	28 931	4 340	30	9 981
Инженер	114 620	17 193	30	39 544
Итого:				49 525

Величина затрат научно-исследовательской работы является основой для формирования бюджета затрат проекта, который при формировании договора с заказчиком защищается научной организацией в качестве нижнего предела затрат на разработку научно-технической продукции. На основе предыдущих расчётов, можно вывести итоговый бюджет НТИ, таблица 16.

Таблица 16 – Расчет бюджет затрат НТИ

Наименование	Сумма, руб.	Удельный вес, %
Амортизация	3 333	2%
Затраты на основную заработную плату	143 551	54%
Затраты на дополнительную заработную плату	21 533	8%
Страховые взносы	49 525	19%
Накладные расходы	43 988	17%
Общий бюджет	261 930	100%

7.3 Определение ресурсной (ресурсосберегающей), финансовой, бюджетной, социальной и экономической эффективности исследования

Определение эффективности происходит на основе расчета интегрального показателя эффективности научного исследования. Его нахождение связано с определением двух средневзвешенных величин: финансовой эффективности и ресурсоэффективности.

Интегральный финансовый показатель разработки определяется как:

$$I_{\text{финр}}^{\text{исп.}i} = \frac{\Phi_{pi}}{\Phi_{\text{max}}}, \quad (7.13)$$

где $I_{\text{финр}}^{\text{исп.}i}$ – интегральный финансовый показатель разработки; Φ_{pi} – стоимость i -го варианта исполнения; Φ_{max} – максимальная стоимость исполнения научно-исследовательского проекта.

$$I_{\Phi}^{\text{исп1}} = \frac{\Phi_i^p}{\Phi_{\text{max}}} = \frac{261\,930}{300\,000} = 0,87 \quad (7.14)$$

$$I_{\Phi}^{\text{исп2}} = \frac{\Phi_i^a}{\Phi_{\text{max}}} = \frac{282\,027}{300\,000} = 0,94 \quad (7.15)$$

$$I_{\Phi}^{\text{исп3}} = \frac{\Phi_i^b}{\Phi_{\text{max}}} = \frac{293\,209}{300\,000} = 0,97 \quad (7.16)$$

Полученная величина интегрального финансового показателя разработки отражает соответствующее численное увеличение бюджета затрат разработки в размах (значение больше единицы), либо соответствующее численное удешевление стоимости разработки в размах (значение меньше единицы, но больше нуля).

Интегральный показатель ресурсоэффективности вариантов исполнения объекта исследования можно определить следующим образом:

$$I_{pi} = \sum_{i=1}^n a_i \cdot b_i, \quad (7.17)$$

где I_{pi} – интегральный показатель ресурсоэффективности для i -го варианта исполнения разработки; a_i – весовой коэффициент i -го варианта исполнения разработки; b_i – балльная оценка i -го варианта исполнения разработки, устанавливается экспертным путем по выбранной шкале оценивания.

$$I_{p \text{ исп1}} = 4,26; I_{p \text{ исп2}} = 4,0; I_{p \text{ исп3}} = 2,95.$$

Интегральный показатель эффективности вариантов исполнения разработки вычисляется на основании показателя ресурсоэффективности и интегрального финансового показателя по формуле:

$$I_{\text{исп.}i} = \frac{I_{p-\text{исп.}i}}{I_{\text{фин.р.}}}; \quad (7.18)$$

$$I_{\text{исп.1}} = \frac{4,26}{0,87} = 4,89; \quad (7.19)$$

$$I_{\text{исп.2}} = \frac{4,0}{0,94} = 4,25; \quad (7.20)$$

$$I_{\text{исп.3}} = \frac{2,95}{0,97} = 3,04. \quad (7.21)$$

Сравнительная эффективность проекта:

$$\mathcal{E}_{\text{ср}} = \frac{I_{\text{исп.}i}}{I_{\text{исп.}j}} \quad (7.22)$$

В таблице 17 представлен анализ сравнительной эффективности разных вариантов исполнения разработки.

Таблица 17 – Сравнительная эффективность проекта

Показатели	VGG16 + Transformer Decoder	VGG16 + Transformer	VGG16 + LSTM
Интегральный финансовый показатель разработки	0,87	0,94	0,97
Интегральный показатель ресурсоэффективности разработки	4,26	4,0	2,95
Интегральный показатель эффективности	4,89	4,25	3,04
Сравнительная эффективность вариантов исполнения	1	1,15	1,61

Таким образом, сравнение значений интегральных показателей эффективности позволило выбрать более эффективный вариант решения поставленной в магистерской диссертации технической задачи с позиции финансовой и ресурсной эффективности. Исходя из интегральных показателей эффективности исполнение VGG16 + Transformer Decoder является эффективней аналогов. Эффект достигается за счёт использования технически сбалансированного решения, которое, не сильно требовательно к ресурсам, является высокоэффективным с точки зрения качества итогового продукта, надёжным и при этом наиболее простым в реализации, значит и наиболее эффективным с точки зрения финансовых затрат на реализацию.

7.4 Выводы по разделу

В данной работе были рассмотрены потенциальные потребители результатов исследования, также проведен анализ конкурентных технических решений. Потенциальными потребителями разработки могут стать крупные компании-владельцы социальных сетей (например VK), средства массовой информации и прочие предприятия, чьи бизнес-процессы связаны с большим количеством медиа-данных.

Далее был сформирован SWOT-анализ, в котором были описаны сильные и слабые стороны проекта, и выявлены возможности и угрозы при реализации проекта.

Был сформирован план проекта, представленный на диаграмме Ганта, из которого видно, какой вид работ осуществлял студент или руководитель и сроки выполнения этих работ.

Был рассчитан интегральный финансовый показатель в ходе оценки бюджета затрат трех вариантов исполнения. Наибольший интегральный показатель реализации задачи равен 0,87. Значение меньше единицы, а значит полученная величина показывает численное удешевление стоимости. Рассчитан интегральный показатель ресурсоэффективности для трех вариантов исполнения 4,26, 4,0 и 2,95. Расчет интегрального показателя эффективности для разработки и аналога позволил сравнить их и рассчитать сравнительную эффективность разработки, которая говорит нам о том, что архитектура VGG16 + Transformer Decoder является наиболее эффективной среди рассмотренных аналогов для задачи генерации текстового описания изображения с позиции финансовой и ресурсной эффективности.

ЗАДАНИЕ ДЛЯ РАЗДЕЛА «СОЦИАЛЬНАЯ ОТВЕТСТВЕННОСТЬ»

Обучающемуся:

Группа		ФИО	
8BM22		Ямкин Никита Николаевич	
Школа	Инженерная школа информационных технологий и робототехники	Отделение (НОЦ)	Отделение информационных технологий
Уровень образования	магистратура	Направление/специальность	09.04.01 Информатика и вычислительная техника

Тема ВКР:

Разработка алгоритма генерации текстового описания изображения на основе нейросетевых архитектур	
Исходные данные к разделу «Социальная ответственность»:	
Введение - Характеристика объекта исследования (вещество, материал, прибор, алгоритм, методика) и области его применения. - Описание рабочей зоны (рабочего места) при разработке проектного решения/при эксплуатации	Объект исследования: алгоритмы генерации текстового описания изображения на основе нейросетевых архитектур. Область применения: социальные медиа и средства массовой информации. Рабочая зона: помещение для размещения средств вычислительной техники и информатики (серверное помещение). Рабочее помещение имеет следующие параметры: - Общая площадь: 15 м²; - Отопление: центральное (радиатор на 4 секции); - Вентиляция: вытяжная 20 см²; - Освещение: 3 светильника. Количество и наименование оборудования рабочей зоны: сервер, коммутатор, маршрутизатор, источник бесперебойного питания, консоль. Рабочие процессы, связанные с объектом исследования, осуществляющиеся в рабочей зоне: оперативное обслуживание техническим персоналом программного обеспечения и серверного оборудования.
Перечень вопросов, подлежащих исследованию, проектированию и разработке:	
1. Правовые и организационные вопросы обеспечения безопасности при эксплуатации: - специальные (характерные при эксплуатации объекта исследования, проектируемой рабочей зоны) правовые нормы трудового законодательства; - организационные мероприятия при компоновке рабочей зоны.	1.Трудовой кодекс Российской Федерации от 30.12.2001 N 197-ФЗ (ред. от 06.04.2024); 2.ГОСТ 12.0.003-2015 Опасные и вредные производственные факторы. Классификация. Перечень опасных и вредных факторов; 3.Федеральный закон «Об обязательном социальном страховании от несчастных случаев на производстве и профессиональных заболеваний» от 24.07.1998 N125-ФЗ; 4.СанПиН 1.2.3685-21 Гигиенические нормативы и требования к обеспечению безопасности и (или) безвредности для человека факторов среды обитания; 5.ГОСТ Р ИСО 9241-4-2009. Эргономические требования к проведению офисных работ с использованием видеодисплейных терминалов (VDT). Часть 5. Требования к расположению рабочей станции и осанке оператора 6.ГОСТ 12.2.032-78 ССБТ. Рабочее место при выполнении работ сидя. Общие эргономические требования. – М.: Изд-во стандартов; 7.ГОСТ 27818-88 Машины вычислительные и системы обработки данных. Допустимые уровни шума на рабочих местах и методы определения. 8.ГОСТ 12.1.003-2014 ССБТ. Шум. Общие требования безопасности.

	9.ГОСТ 12.1.003-83 Система стандартов безопасности труда (ССБТ). Шум. Общие требования безопасности 10. СН 2.2.4/2.1.8.566-96 «Производственная вибрация, вибрация в помещениях жилых и общественных зданий» 11.ГОСТ 12.1.012-2004 Система стандартов безопасности труда (ССБТ). Вибрационная безопасность. Общие требования 12. ГОСТ 12.1.038-82 «Электробезопасность. Предельно допустимые значения напряжений прикосновения и токов»; 13. ГОСТ Р 12.1.019-2009 «Электробезопасность. Общие требования и номенклатура видов защиты»; 14. СП 52.13330.2016 Естественное и искусственное освещение. Актуализированная редакция СНиП 23-05-95 15. ГОСТ Р 55102-2012 «Ресурсосбережение. Обращение с отходами. Руководство по безопасному сбору, хранению, транспортированию и разборке отработавшего электротехнического и электронного оборудования, за исключением ртутьсодержащих устройств и приборов» 16. ГОСТ 17.4.3.04-85 Охрана природы (ССОП). Почвы. Общие требования к контролю и охране от загрязнения 17. ГОСТ Р 53692-2023 Ресурсосбережение. Обращение с отходами. Этапы технологического цикла отходов 18. ГОСТ 12.3.031-83 «Работы со ртутью. Требования безопасности» 19. ГОСТ Р 51768-2001 Ресурсосбережение. Обращение с отходами. Методика определения ртути в ртутьсодержащих отходах. Общие требования 20. ГОСТ Р 55090-2012 Ресурсосбережение. Обращение с отходами. Рекомендации по утилизации отходов бумаги 21.ГОСТ 12.1.004-91 Система стандартов безопасности труда (ССБТ). Пожарная безопасность. Общие требования 22. СП 12.13130.2009 «Определение категорий помещений, зданий и наружных установок по взрывопожарной и пожарной опасности» 23. Приказ Министерства энергетики РФ от 12 августа 2022 г. № 811 «Об утверждении Правил технической эксплуатации электроустановок потребителей электрической энергии» 24. Приказ Министерства труда и социальной защиты РФ от 15 декабря 2020 года № 903н «Об утверждении Правил по охране труда при эксплуатации электроустановок» 25. Правила устройства электроустановок (ПУЭ)
2. Производственная безопасность при эксплуатации: - Анализ выявленных вредных и опасных производственных факторов - Расчет уровня опасного или вредного производственного фактора	Вредные факторы: 1. Повышенный уровень и другие неблагоприятные характеристики шума; 2. Факторы, связанные с аномальными микроклиматическими параметрами воздушной среды на местонахождении рабочего (температура, тепловое излучение окружающих поверхностей, влажность); 3. Повышенный уровень локальной вибрации; 4. Отсутствие или недостаток необходимого искусственного освещения. Опасные факторы: 1. Факторы, связанные с электрическим током, вызываемым разницей электрических потенциалов, под действие которого попадает рабочий. Средства коллективной защиты: оградительные устройства; звукоизолирующие, звукопоглощающие устройства; глушители шума; защитные покрытия;

	изолирующие устройства и покрытия; устройства защитного заземления и зануления; устройства для вентиляции и очистки воздуха; термоизолирующие устройства; устройства автоматического отключения; устройства автоматического контроля и сигнализации; предохранительные устройства; устройства дистанционного управления. Средства индивидуальной защиты: - рук – перчатки; - глаз и лица – очки, щитки; - органов дыхания – респираторы, противогазы; - органов слуха – наушники, беруши. Расчет: расчет системы искусственного освещения.
3. Экологическая безопасность <u>при эксплуатации</u>:	Воздействие на селитебную зону: ликвидация (с утилизацией и/или удалением) изделий по истечении срока их службы или в связи с моральным старением. Воздействие на литосферу: ликвидация (с утилизацией и/или удалением) изделий по истечении срока их службы или в связи с моральным старением. Воздействие на гидросферу: отсутствует. Воздействие на атмосферу: отсутствует.
4. Безопасность в чрезвычайных <u>при эксплуатации</u>	Возможные ЧС: 1. Природная – сильные морозы зимой, (аварии на электро-, тепло-коммуникациях, водоканале, транспорте); 2. Техногенная – пожар. Наиболее типичная ЧС: пожар.
Дата выдачи задания для раздела по линейному графику	

Задание выдал консультант:

Должность	ФИО	Ученая степень	Подпись	Дата
Профессор ОКД ИШНКБ	Федоренко Ольга Юрьевна	Д.М.Н.		

Задание принял к исполнению обучающийся:

Группа	ФИО	Подпись	Дата
8BM22	Ямкин Никита Николаевич		

8 Социальная ответственность

8.1 Введение

В рамках магистерской диссертации разрабатывался алгоритм генерации текстового описания изображения на основе нейросетевых архитектур.

Данный алгоритм полезен при поиске в больших коллекциях конкретных изображений или видео на основе их содержания.

Область применения: социальные медиа и средства массовой информации.

Потенциальными пользователями разработки могут стать пользователи социальных сетей, слабовидящие люди (в данном случае подразумевается использование алгоритма, как часть голосового помощника). Алгоритм также может быть использован научно-исследовательскими институтами, университетами и проектными организациями для создания комплексного продукта или для исследований.

И программное и аппаратное обеспечение должны постоянно обслуживаться техническим персоналом для бесперебойной работы всей системы и предотвращения возникновения аварийных ситуаций.

Рабочим местом технического персонала является серверное помещение общей площадью 15 м², с центральным отоплением (радиатор на 4 секции), с вытяжной вентиляцией на 20 см² и тремя светильниками, оборудованное вычислительной техникой, системами климат-контроля, источниками бесперебойного питания, автоматическими системами пожаротушения, системами ограничения доступа в помещение и звукоизоляцией.

Данный раздел направлен на анализ вредных и опасных факторов, негативно влияющих на человека и окружающую среду, анализ возможных чрезвычайных ситуаций и выявление мер по защите окружающей среды и персонала. Также в разделе рассматриваются правила поведения при возникновении чрезвычайной ситуации.

8.2 Правовые и организационные вопросы обеспечения безопасности

8.2.1 Правовые нормы трудового законодательства

Трудовой кодекс Российской Федерации от 30.12.2001 N 197–ФЗ [31] устанавливает следующие правила для рабочих:

- количество рабочих часов в неделю не должно превышать сорока часов;
- продолжительность рабочего дня перед праздничным или выходным днём уменьшается на один час;
- работникам раз в год предоставляются отпуска продолжительностью 28 дней с сохранением места работы (должности) и среднего заработка;
- в течение рабочего дня работнику должен предоставляться, перерыв не более двух часов и не менее 30 минут, не включаемый в рабочее время;
- работа в выходные дни проводится только с согласия работника.

Федеральный закон N125-ФЗ [33] устанавливает в Российской Федерации правовые, экономические и организационные основы обязательного социального страхования от несчастных случаев на производстве профессиональных заболеваний и определяет порядок возмещения вреда, причиненного жизни и здоровью работника при исполнении им обязанностей по трудовому договору и в иных установленных случаях.

Обеспечение по страхованию осуществляется:

1. В виде пособия по временной нетрудоспособности;
2. В виде страховых выплат (единовременной или ежемесячной);
3. В виде оплаты дополнительных расходов, связанных с медицинской, социальной и профессиональной реабилитацией застрахованного.

8.2.2 Эргономические требования к рабочему месту

При компоновки рабочей зоны необходимо учесть то, что основную часть работы инженер проводит перед монитором в неподвижном положении, следовательно, следует рассмотреть ряд вопросов, касающийся компоновки рабочего места с учётом эргономики.

По категории тяжести труда в соответствие с СанПин 1.2.3685-21 [34] работа технического персонала относится к категории 1а, так как работы производятся сидя и сопровождаются незначительным физическим напряжением.

Согласно ГОСТ 12.2.032-78 ССБТ [36] рабочее место для выполнения работ сидя организуют при легкой работе, не требующей свободного передвижения работающего, а также при работе средней тяжести в случаях, обусловленных особенностями технологического процесса. Конструкция рабочего места и взаимное расположение всех его элементов (сиденье, органы управления, средства отображения информации и т.д.) должны соответствовать антропометрическим, физиологическим и психологическим требованиям, а также характеру работы.

Высота рабочего места подбирается исходя из видов работ, которые будут выполняться на производстве, в данном случае работа будет связана с ЭВМ, следовательно, рабочее место будет настраиваться в пределах от 680-750 мм над уровнем пола. Конструкция регулируемого кресла должна обеспечивать оптимальную рабочую позу для конкретного роста.

В соответствии с ГОСТ Р ИСО 9241-4-2009 [35], пользователь должен иметь возможность наклонить или повернуть видеодисплей таким образом, чтобы сохранить ненапряженную рабочую позу независимо от высоты уровня глаз с минимальными прилагаемыми усилиями, и при этом на экране не должно возникать раздражающих отражений и бликов.

Адаптируемость обеспечивают с помощью регулирующих механизмов, встроенных в видеодисплей, или специальными устройствами, которые являются частью офисного оборудования или непосредственно дисплея.

Механизмы настройки должны быть понятны, однозначны, а регулировка должна быть легко выполнима.

8.3 Производственная безопасность

Таблица 18 – Возможные опасные и вредные производственные факторы в серверном помещении

Факторы (ГОСТ 12.0.003-2015) [32]	Нормативные документы
Повышенный уровень и другие неблагоприятные характеристики шума	ГОСТ 27818-88 Машины вычислительные и системы обработки данных. Допустимые уровни шума на рабочих местах и методы определения. [37] ГОСТ 12.1.003-2014 ССБТ. Шум. Общие требования безопасности. [38] ГОСТ 12.1.003-83 Система стандартов безопасности труда (ССБТ). Шум. Общие требования безопасности [39]
Факторы, связанные с аномальными микроклиматическими параметрами воздушной среды на местонахождении рабочего (температура, тепловое излучение окружающих поверхностей, влажность)	СанПиН 1.2.3685-21 Гигиенические нормативы и требования к обеспечению безопасности и (или) безвредности для человека факторов среды обитания. [34]
Повышенный уровень общей вибрации	СН 2.2.4/2.1.8.566-96 «Производственная вибрация, вибрация в помещениях жилых и общественных зданий» [40] ГОСТ 12.1.012-2004 Система стандартов безопасности труда (ССБТ). Вибрационная безопасность. Общие требования [41]
Отсутствие или недостаток необходимого искусственного освещения	СП 52.13330.2016 Естественное и искусственное освещение. Актуализированная редакция СНиП 23-05-95 [44]
Факторы, связанные с электрическим током, вызываемым разницей электрических потенциалов, под действие которого попадает рабочий	ГОСТ 12.1.038-82 «Электробезопасность. Предельно допустимые значения напряжений прикосновения и токов» [42] ГОСТ Р 12.1.019-2009 «Электробезопасность. Общие требования и номенклатура видов защиты» [43] Приказ Министерства энергетики РФ от 12 августа 2022 г. № 811 «Об утверждении Правил технической эксплуатации электроустановок потребителей электрической энергии» [53] Приказ Министерства труда и социальной защиты РФ от 15 декабря 2020 года № 903н «Об утверждении Правил по охране труда при эксплуатации электроустановок» [54]

8.3.1 Анализ вредных факторов

8.3.1.1 Повышенный уровень и другие неблагоприятные характеристики шума

Основными источниками шума в серверном помещении являются: серверы и сетевое оборудование (а именно вентиляторы внутри корпусов серверов и коммутаторов, вращающиеся жесткие диски), кондиционеры и вентиляционные установки, источники бесперебойного питания.

Шум ухудшает условия труда, оказывая вредное действие на организм человека. Работающие в условиях длительного шумового воздействия испытывают раздражительность, головные боли, головокружение, снижение памяти, повышенную утомляемость, боли в ушах и т. д. Под воздействием шума снижается концентрация внимания, нарушаются физиологические функции, появляется усталость в связи с повышенными энергетическими затратами и нервно-психическим напряжением.

По ГОСТ 27818-88 [37], допустимое значение эквивалентного уровня звука на рабочих местах обслуживания устройств в вычислительных центрах не должно превышать 70дБ.

Согласно ГОСТ 12.1.003-2014 ССБТ [38] на работодателе лежит основная ответственность за обеспечение безопасности при воздействии шума на работников. В первую очередь он должен обеспечить посредством принятия соответствующих мер соблюдение гигиенических нормативов и снижение риска, связанного с воздействием шума на работников. Эти меры могут включать в себя, в частности:

- оценку риска потери слуха работником;
- проектирование рабочих мест с учетом допустимых уровней риска;
- использование малошумных машин. При этом ГОСТ 12.1.003-83 [39]

обязывает установку предельных значений шумовых характеристик на каждую вычислительную машину;

- использование материалов и конструкций, препятствующих распространению шума и прочее;

Если особенности производства не позволяют работодателю снизить шум на рабочем месте до требуемого уровня, то в качестве дополнительной меры рассматривается возможность использования средств индивидуальной защиты от шума (наушники или беруши) [38].

Также, в качестве профилактической меры, предлагается осуществлять эффективное управление временем работы и отдыха для предотвращения переутомления и снижения воздействия шума на работников;

8.3.1.2 Факторы, связанные с аномальными микроклиматическими параметрами воздушной среды

Источники аномальных микроклиматических параметров в помещении:

- тепловыделение вычислительного оборудования;
- неправильно настроенная система охлаждения;
- нарушение герметичности (неплотно закрытые двери и т.д.)
- аварийные ситуации (поломки в системе охлаждения, отключение электропитания и т.д.).

Высокая температура в помещении может быть причиной теплового удара и нарушения терморегуляции работника. Неравномерное распределение температуры в помещении повышает риск возникновения простудных заболеваний.

Низкая влажность вызывает сухость и раздражение слизистых оболочек, обостряет хронические заболевания.

Требования СанПиН 1.2.3685-21 [34] описывают параметры микроклимата в офисах. Они зависят от сезона – холодный или тёплый. Также на данные значения влияет категория физической тяжести работы (категория

1а). Документ описывает как оптимальные, так и допустимые величины показателей микроклимата.

Таблица 19 – Оптимальные значения характеристик микроклимата по СанПиН 1.2.3685-21

Период года	Температура воздуха, °С	Температура поверхности, °С	Относительная влажность, %	Скорость движения воздуха, м/с
Холодный	22-24	21-25	40-60	0,1
Теплый	23-25	22-26		

Таблица 20 – Допустимые величины показателей микроклимата по СанПиН 1.2.3685-21

Период года	Температура воздуха, °С	Температура поверхностей, °С	Относительная влажность, %	Скорость движения воздуха, м/с
Холодный	19-24	18-25	15-75	0,1-0,2
Теплый	20-28	19-29		0,1-0,3

Для предотвращения возможного возникновения рассматриваемого вредного фактора важно обеспечить помещение системами кондиционирования, отопления и вентиляции, датчиками контроля температуры, влажности и давления, обеспечить герметичность помещения. Также требуется организовать дистанционный мониторинг за всеми вышеупомянутыми системами и проводить их регулярное обслуживание.

8.3.1.3 Повышенный уровень общей вибрации

Источниками общей вибрации в серверном помещении являются серверы, сетевое и телекоммуникационное оборудование, системы кондиционирования и вентиляции, источники электропитания. Таким образом, по природе возникновения общая вибрация на рабочем месте соответствует 3 категории (технологическая вибрация), а по месту действия относится к подкатегории В (вычислительный центр) [40].

Повышенная вибрация воздействует на нервную систему работников, повышает раздражительность, снижает концентрацию внимания и остроту зрения, может стать причиной головокружения.

По СН 2.2.4/2.1.8.566-96 (таблица 8) [40], предельно допустимый уровень виброускорения на рабочем месте категории 3 типа В равен $0,01 \text{ м/с}^2$, при частоте 10 Гц.

Согласно ГОСТ 12.1.012-2004 ССБТ [41] на работодателе лежит основная ответственность за соблюдение установленных гигиенических нормативов по вибрации в рабочей зоне. Для этого он должен оценить риск, связанный с воздействием вибрации на рабочих, и принять меры, необходимые для снижения вибрационной нагрузки. Эти меры могут включать в себя, в частности:

- проектирование рабочих мест с учетом максимального снижения вибрации;
- использование машин с меньшей виброактивностью и их оптимальное размещение;
- использование материалов и конструкций, препятствующих распространению вибрации и воздействию ее на человека;
- организацию профилактических мероприятий, ослабляющих неблагоприятное воздействие вибрации;
- организация контроля и мониторинга уровня вибрации в помещении;
- регулярное техническое обслуживание устройств;
- применение средств индивидуальной защиты (специальные перчатки, обувь).

8.3.1.4 Отсутствие или недостаток необходимого искусственного освещения

Источники возникновения: отсутствие возможности организации естественного освещения.

Согласно СП 52.13330.2016 [44] при работах III зрительного разряда и подразряда Г (работы высокой точности) освещенность при системе общего освещения должна быть не ниже 200 лк.

Плохое освещение негативно воздействует на зрение, приводит к быстрому утомлению, снижает работоспособность, вызывает дискомфорт, является причиной головной боли и бессонницы.

Для обеспечения рационального освещения необходимо правильно подобрать светильники в сочетании с естественным светом, поддерживать чистоту оконных стекол и поверхностей светильников.

Внесём параметры помещения в таблицу.

Таблица 21 – Параметры помещения

Параметр	Обозначение	Значение
Длина	A	5 м
Ширина	B	3 м
Высота помещения	H	3,5 м
Свес	h_c	0,4 м
Высота рабочей поверхности	h_{rp}	0,8 м
Высота от светильника до рабочей поверхности	h	2,3 м
Коэффициент отражения стен	ρ_c	50 %
Коэффициент отражения потолка	ρ_n	70 %
Коэффициент запаса	K_z	1,8
Коэффициент неравномерности	Z	1,1

Расчет общего равномерного искусственного освещения горизонтальной рабочей поверхности выполняется методом коэффициента использования светового потока, учитывающим световой поток, отраженный от потолка и стен.

Световой поток лампы определяется по формуле:

$$\Phi = \frac{E \cdot A \cdot B \cdot K_z \cdot Z}{N_{\text{л}} \cdot \eta} \quad (8.1)$$

Площадь помещения:

$$S = A \cdot B = 5 \cdot 3 = 15 \text{ м}^2 \quad (8.2)$$

Согласно нормативным документам, принятым в предприятии, помещение должно быть освещено пылевлагозащищёнными светильниками типа ПВЛ для пожароопасных помещений с двумя лампами ЛБ со световым потоком $\Phi_{\text{п}} = 2800$ Лм. По паспорту длина светильника $A_{\text{св}} = 1230$ мм, ширина $B_{\text{св}} = 266$ мм, высота $H_{\text{св}} = 158$ мм. Мощность лампы – 40 Вт.

Индекс помещения определяется по формуле:

$$i = \frac{A \cdot B}{h \cdot (A + B)} = \frac{5 \cdot 3}{2,3 \cdot (5 + 3)} = 0,81 \quad (8.3)$$

Из методической таблицы коэффициент использования светового потока, показывающий какая часть светового потока ламп попадает на рабочую поверхность, для светильников типа ПВЛ с люминесцентными лампами при $\rho_{\text{с}} = 50\%$, $\rho_{\text{п}} = 70\%$ и индексе помещения $i = 0,81$ равен $\eta = 45\%$.

Из формулы светового потока получим, что общее количество люминесцентных ламп: $N_{\text{л}} = 5$. Соответственно количество светильников типа ПВЛ: $N_{\text{св}} = 3$.

Расчет светового потока группы люминесцентных ламп:

$$\Phi_{\text{рас}} = \frac{E \cdot A \cdot B \cdot K_{\text{з}} \cdot Z}{N_{\text{л}} \cdot \eta} = \frac{200 \cdot 5 \cdot 3 \cdot 1,8 \cdot 1,1}{5 \cdot 0,45} = 2640 \text{ Лм} \quad (8.4)$$

Делаем проверку выполнения условия:

$$-10\% \leq \frac{\Phi_{\text{п}} - \Phi_{\text{рас}}}{\Phi_{\text{п}}} \cdot 100\% \leq 20\% \quad (8.5)$$

$$-10\% \leq \frac{2800 - 2640}{2800} \cdot 100\% \leq 20\% \quad (8.6)$$

$$-10\% \leq 5,7\% \leq 20\% \quad (8.7)$$

Видим, что необходимый световой поток светильника не выходит за пределы требуемого диапазона.

Мощность осветительной установки рассчитывается по формуле:

$$P_{\text{уст}} = N \cdot P_{\text{л}} = 5 \cdot 40 = 200 \text{ Вт} \quad (8.8)$$

Теперь определим расстояния между светильниками по длине помещения по следующей формуле.

$$5000 = 2 \cdot L_A + 3 \cdot 1230 + \frac{2}{3} \cdot L_A \quad (8.9)$$

$$L_A = (5000 - 3690) \cdot \frac{3}{8} = 491 \text{ мм} \quad (8.10)$$

$$\frac{L_A}{3} = 164 \text{ мм} \quad (8.11)$$

Так как у нас всего один ряд светильников, то установим их по середине ширины.

$$3000 = 2 \cdot l + 266 \quad (8.12)$$

$$l = (3000 - 266) \cdot \frac{1}{2} = 1367 \text{ мм} \quad (8.13)$$




Рисунок 37 – План размещения светильников на потолке

8.3.2 Анализ опасных факторов

8.3.2.1 Факторы, связанные с электрическим током

Электрический ток представляет собой скрытый тип опасности, т.к. его трудно определить в токо- и нетоковедущих частях оборудования, которые являются хорошими проводниками электричества. Согласно ГОСТ 12.1.038-82 [42], смертельно опасным для жизни человека считают ток, величина которого превышает 0,05 А, ток менее 0,05 А – безопасен (до 1000 В).

Зоной, повышенной электроопасности являются места подключения электроприборов и установок.

Серверное оборудование работает от сети переменного напряжения 220 В и частотой 50 Гц. Данный вид оборудования является потенциальными источником опасности поражения человека электрическим током. При его обслуживании возможен удар током при соприкосновении с токоведущими частями оборудования.

Для обеспечения безопасности в данном случае необходимо установить защитные барьеры или ограждения вблизи от серверного шкафа и поставить табличку «Опасно. Высокое напряжение».

Для обеспечения защиты от случайного прикосновения к токоведущим частям необходима изоляция токоведущих частей и установка защитных предохранителей, заземления и зануления [43].

Все сотрудники, работающие в помещении, должны иметь категорию «оперативно-ремонтный персонал» на основании п.38 Приказа Министерства энергетики РФ [53].

Персонал, обслуживающий электроустановки (при их напряжении до 1000 В), должен иметь группу по электробезопасности не ниже III в соответствии с п.3.2. Приказа Министерства труда и социальной защиты РФ [54].

8.4 Экологическая безопасность

Основные устройства, используемые в работе, это ЭВМ и принтер, что ведет к чрезмерному потреблению энергии и различных расходных материалов: картриджи, бумага.

В компьютерах огромное количество компонентов, которые содержат токсичные вещества и представляют угрозу, как для человека, так и для окружающей среды, при их неправильной утилизации.

К таким веществам относятся:

- свинец (накапливается в организме, поражая почки, нервную систему);
- ртуть (поражает мозг и нервную систему);
- никель и цинк (могут вызывать дерматит);
- щелочи (прожигают слизистые оболочки и кожу);

Поэтому компьютер требует специальных комплексных методов утилизации. Таким образом утилизацию компьютера можно провести, согласно ГОСТ Р 55102-2012 [45].

Бумага является самым распространенным побочным продуктом в виде разных документов и чертежей. Снизить потребление и, соответственно, отходы бумаги можно с помощью перехода с бумажных на цифровые носители, введением цифрового документооборота и систем САПР. Также существуют программы по утилизации и переработке макулатуры, согласно ГОСТ Р 53692-2023 [47] в новый бумажный продукт, что снижает потребность в вырубке лесов. При правильной переработке более 75% макулатуры попадает во вторичный оборот. Утилизация отходов бумаги производится согласно ГОСТ Р 55090-2012 [50].

Картриджи необходимо сдать в организацию, занимающуюся их утилизацией. Утилизация картриджей проводится двумя способами:

- Наиболее распространенный способ – переработка с последующим использованием для новых изделий. Многие компании-производители собранные отработанные изделия передают дочерним перерабатывающим организациям.

- Другой способ – механическое и термическое разложение. Изделия подвергаются сортировке и разделению на составляющие компоненты, после чего пластиковые и металлические части измельчают и переплавляют при высокой температуре с получением вторсырья.

Оба способа выполняются согласно ГОСТ 17.4.3.04-85 Охрана природы (ССОП). Почвы. Общие требования к контролю и охране от загрязнения [46].

Так же в ходе работы может выйти из строя люминесцентная лампа, которая является опасным отходом, так как при нарушении целостности корпуса выделяться пары ртути. Методы безопасной утилизации данного продукта регламентирована по ГОСТ 12.3.031-83 [48], и в случае поломки будут сданы в пункт приёма отработанных люминесцентных ламп. В г. Томске таких пункта два и оба принадлежат компании «Экотом».

Чтобы решить проблему чрезмерного использования разных расходных материалов (картриджей, бумаги), для предварительных проверок можно использовать бумагу с двух сторон.

8.5 Безопасность в чрезвычайных ситуациях

При эксплуатации разработанного программного обеспечения могут возникать чрезвычайные ситуации различного характера: техногенные или природные. Однако наиболее типичной ситуацией является возникновение пожара. Данная ЧС может быть вызвана как неисправностью электропроводки, так и нарушением мер пожаробезопасности.

Возникновение пожара в рассматриваемом помещении обуславливается следующими факторами: работа с открытой электроаппаратурой, короткое замыкание в блоке питания, нарушенная изоляция электрических проводов, несоблюдение правил пожарной безопасности, наличие горючих

компонентов: документы, двери, столы, изоляция кабелей и т.п.; наличие кислорода, как окислителя процессов горения.

Источниками возгорания в серверной могут быть электронные схемы от ЭВМ, приборы, применяемые для технического обслуживания, устройства электропитания, где в результате различных нарушений образуются перегретые элементы, электрические искры и дуги, способные вызвать возгорания горючих материалов.

Пожарная профилактика основывается на устранении благоприятных условий возгорания. В рамках обеспечения пожарной безопасности решаются четыре задачи: предотвращение пожаров и возгорания, локализация возникших пожаров, защита людей и материальных ценностей, тушение пожара.

Организационные мероприятия по пожарной профилактике предусматривают правильную эксплуатацию оборудования, правильное содержание зданий и территорий, противопожарный инструктаж рабочих и служащих, обучение производственного персонала правилам противопожарной безопасности, издание инструкций, плакатов, наличие плана эвакуации.

К техническим мероприятиям относятся: соблюдение противопожарных правил, норм при проектировании зданий, при устройстве электропроводов и оборудования, отопления, вентиляции, освещения, правильное размещение оборудования.

Помещения для размещения вычислительной техники относятся, в соответствии гл. 7.4 Правил устройства электроустановок (ПУЭ), к классу пожаробезопасности П-Па (степень огнестойкости) [55].

В комнате не перерабатываются горючие вещества (материалы), т. е. горючая пыль или пары отсутствуют. Компьютерное оборудование выполняется из пожаробезопасных материалов. В комнате не хранятся жидкое или твердое топливо, горючие газы, взрывоопасные вещества и пр. Таким образом, согласно СП 12.13130.2009 [52], серверная комната относится к

одной из категорий В (В1 – В4) – пожароопасные помещения, а возможный пожар может относиться к классу А, так и классу Е.

В соответствии с приведенным нормативным документом, пространство внутри должно отделяться несгораемыми стенами (перегородками) с пределом огнестойкости не менее 0,75 ч. Двери в этих стенах и перегородках должны быть с пределом огнестойкости не менее 0,6 ч.

Серверная (основная и резервная) и телекоммуникационная должны оборудоваться автоматическими установками газового пожаротушения (АУГП). Огнегасящим веществом должен быть газ, который имеет российский сертификат. Таким средством тушения может быть газ «игмер» или двуокись углерода.

Комплекс мероприятий, описанных в ГОСТ 12.1.004-91 [51], позволяют уменьшить вероятность возникновения пожара и более оперативно ликвидировать последствия:

- регулярная проверка систем оповещения и тушения;
- отключение оборудования при покидании рабочего места;
- проведение инструктажа работников по действиям при пожаре;
- проведение учебной тревоги два раза в год;
- установка систем противопожарной сигнализации;
- закупка огнетушителей;
- оборудование запасных выходов при пожаре;
- создание плана эвакуации и размещение его экземпляров в доступных местах.

Пожарная безопасность в офисном помещении обеспечивается системой пожарной сигнализации. Имеется план эвакуации, закреплен ответственный за пожарную безопасность.



Рисунок 38 – План эвакуации при пожаре и других ЧС

8.6 Вывод

В результате написания данного раздела ВКР были изучены правовые и организационные вопросы обеспечения безопасности, изучены правовые нормы трудового законодательства и требования к компоновке рабочей зоны, в которой будет эксплуатироваться разрабатываемое программное обеспечение.

Была рассмотрена производственная безопасность, в т.ч. проанализированы вредные и опасные факторы, которые могут возникнуть при эксплуатации ПО. Предложены мероприятия по защите работников от действия опасных и вредных факторов.

Был рассмотрен характер воздействия на окружающую среду и проведен анализ возможных чрезвычайных ситуаций, которые могут возникнуть при эксплуатации проектируемого решения.

Персонал, обслуживающий электроустановки (при их напряжении до 1000 В), должен иметь группу по электробезопасности не ниже III в соответствии с п.3.2. Приказа Министерства труда и социальной защиты РФ [54].

Рабочее помещение оборудовано в соответствии с требованиями электро- и пожарной безопасности.

Помещения для размещения вычислительной техники относятся, в соответствии гл. 7.4 Правил устройства электроустановок (ПУЭ) [55], к классу пожаробезопасности П-Па.

Согласно СП 12.13130.2009 [52], рабочее помещение является пожароопасным и относится к категории В, а возможный пожар может относиться к классу А, так и классу Е.

По категории тяжести труда в соответствии с СанПин 1.2.3685-21 [34] работа технического персонала относится к категории 1а, так как работы производятся сидя и сопровождаются незначительным физическим напряжением.

Заключение

В ходе выполнения выпускной квалификационной работы были рассмотрены, реализованы и сравнены между собой три нейросетевых архитектуры моделей для генерации текстовых описаний изображения.

Результаты экспериментов показали, что наилучшие показатели по метрикам BLEU, BERT score и визуальной оценке были достигнуты моделью, использующей VGG16 в качестве визуального энкодера, и Transformer Decoder с 8 головами внимания.

Данная архитектура продемонстрировала способность генерировать наиболее содержательные, связные и релевантные описания изображений по сравнению с другими рассмотренными подходами, при наименьшем времени обучения.

Был проведен анализ финансовой и ресурсной эффективности рассматриваемого проекта, который показал, что наиболее конкурентоспособной и эффективной в коммерциализации является та же модель VGG16+Transformer Decoder.

Также были выявлены возможные вредные и опасные факторы, которые могут возникнуть во время эксплуатации продукта, и пути их устранения.

Список использованных источников

1. Бегин А. Сколько данных создается каждый день? (июнь 2024) // ИНКЛИЕНТ [Электронный ресурс]. URL: <https://incliент.ru/data-create-stats/#lwptoc> (дата обращения 01.06.2024).
2. Коршунова К. П. Задачи и методы автоматического описания изображений // Системы управления, связи и безопасности. 2018. № 1. С. 30–77 [Электронный ресурс]. URL: <http://sccs.intelgr.com/archive/2018-01/02-Korshunova.pdf> (дата обращения 01.06.2024).
3. Farhadi A. et al. Every picture tells a story: Generating sentences from images //Computer Vision–ECCV 2010: 11th European Conference on Computer Vision, Heraklion, Crete, Greece, September 5-11, 2010, Proceedings, Part IV 11. – Springer Berlin Heidelberg, 2010. – С. 15-29. (дата обращения 01.06.2024).
4. Kulkarni G. et al. Babytalk: Understanding and generating simple image descriptions //IEEE transactions on pattern analysis and machine intelligence. – 2013. – Т. 35. – №. 12. – С. 2891-2903. (дата обращения 01.06.2024).
5. Vinyals O. et al. Show and tell: A neural image caption generator //Proceedings of the IEEE conference on computer vision and pattern recognition. – 2015. – С. 3156-3164. (дата обращения 01.06.2024).
6. Nallapaneni S. S., Konakanchi S. A Comprehensive Analysis of Real-World Image Captioning and Scene Identification //arXiv preprint arXiv:2308.02833. – 2023. (дата обращения 01.06.2024).
7. Zhu X. et al. Captioning transformer with stacked attention modules //Applied Sciences. – 2018. – Т. 8. – №. 5. – С. 739. (дата обращения 01.06.2024).
8. Практика по машинному обучению. Задача Image Captioning - описание изображения текстом нейросетью. // YouTube. [Электронный ресурс]. URL: <https://www.youtube.com/watch?v=wSVnLV29VY&t=1726s> (дата обращения 01.06.2024).
9. Simonyan K., Zisserman A. Very deep convolutional networks for large-scale image recognition //arXiv preprint arXiv:1409.1556. – 2014. (дата обращения 01.06.2024).

10. Милютин И. VGG16 – нейросеть для выделения признаков изображений // Neurohive [Электронный ресурс]. URL: <https://neurohive.io/ru/vidy-nejrosetej/vgg16-model/> (дата обращения 01.06.2024).

11. Arjun Sarkar EfficientNetV2: Faster, Smaller, and Higher Accuracy than Vision Transformers // Towards Data Science [Электронный ресурс]. URL: <https://towardsdatascience.com/efficientnetv2-faster-smaller-and-higher-accuracy-than-vision-transformers-98e23587bf04> (дата обращения 01.06.2024).

12. Tan M., Le Q. Efficientnetv2: Smaller models and faster training //International conference on machine learning. – PMLR, 2021. – С. 10096-10106. (дата обращения 01.06.2024).

13. Lee T. et al. Identification of individual Hanwoo cattle by muzzle pattern images through deep learning //Animals. – 2023. – Т. 13. – №. 18. – С. 2856. (дата обращения 01.06.2024).

14. He K. et al. Deep residual learning for image recognition //Proceedings of the IEEE conference on computer vision and pattern recognition. – 2016. – С. 770-778. (дата обращения 01.06.2024).

15. Ramzan F. et al. A deep learning approach for automated diagnosis and multi-class classification of Alzheimer’s disease stages using resting-state fMRI and residual neural networks //Journal of medical systems. – 2020. – Т. 44. – С. 1-16. (дата обращения 01.06.2024).

16. Rahuljha LSTM Gradients // Towards Data Science [Электронный ресурс]. URL: <https://towardsdatascience.com/lstm-gradients-b3996e6a0296> (дата обращения 01.06.2024).

17. Wunder Fund LSTM – сети долгой краткосрочной памяти // Хабр [Электронный ресурс]. URL: <https://habr.com/ru/companies/wunderfund/articles/331310/> (дата обращения 01.06.2024).

18. Bahdanau D., Cho K., Bengio Y. Neural machine translation by jointly learning to align and translate //arXiv preprint arXiv:1409.0473. – 2014. (дата обращения 01.06.2024).
19. Deep Learning School Лекция. Внимание (Attention) // YouTube. [Электронный ресурс]. URL: <https://www.youtube.com/watch?v=G4vT5cvJSxY> (дата обращения 01.06.2024).
20. Vaswani A. et al. Attention is all you need //Advances in neural information processing systems. – 2017. – Т. 30. (дата обращения 01.06.2024).
21. Deep Learning School Лекция. Механизм внимания (Attention) // YouTube. [Электронный ресурс]. URL: <https://www.youtube.com/watch?v=Fki-Xe3CGg8&t=1218s> (дата обращения 01.06.2024).
22. Deep Learning School Лекция. Архитектура Transformer. Введение, Transformer Encoder // YouTube. [Электронный ресурс]. URL: <https://www.youtube.com/watch?v=TBEwpgyoo20> (дата обращения 01.06.2024).
23. Deep Learning School Лекция. Архитектура Transformer. Decoder, QKV Attention // YouTube. [Электронный ресурс]. URL: <https://www.youtube.com/watch?v=tsee8mosj5U&t=1201s> (дата обращения 01.06.2024).
24. Zhang T. et al. Bertscore: Evaluating text generation with bert //arXiv preprint arXiv:1904.09675. – 2019. (дата обращения 01.06.2024).
25. Michael Avendi PyTorch torchvision COCO Dataset // Medium [Электронный ресурс]. URL: <https://medium.com/howtoai/pytorch-torchvision-coco-dataset-b7f5e8cad82> (дата обращения 01.06.2024).
26. Chen X. et al. Microsoft coco captions: Data collection and evaluation server //arXiv preprint arXiv:1504.00325. – 2015. (дата обращения 01.06.2024).
27. Rahmad Sadli COCO Dataset: A Step-by-Step Guide to Loading and Visualizing with Custom Code // Machine Learning Space [Электронный ресурс]. URL: <https://machinelearningspace.com/coco-dataset-a-step-by-step-guide-to-loading-and-visualizing/#step3> (дата обращения 01.06.2024).

28. Daniel Melchor A detailed guide to PyTorch's nn.Trabsformer() module // Towards Data Science [Электронный ресурс]. URL: <https://towardsdatascience.com/a-detailed-guide-to-pytorchs-nn-transformer-module-c80afbc9ffb1> (дата обращения 01.06.2024).

29. Mayankkeshari Image Captioning using Transformers // Medium [Электронный ресурс]. URL: <https://medium.com/@mayankkeshari34/image-captioning-using-transformers-627cd39c6b7a> (дата обращения 01.06.2024).

30. Stephen Lau Caption Your Images with a CNN-Transformer Hybrid Model // Medium [Электронный ресурс]. URL: <https://heartbeat.comet.ml/caption-your-images-with-a-cnn-transformer-hybrid-model-a980f437da7b> (дата обращения 01.06.2024).

31. Трудовой кодекс Российской Федерации от 30.12.2001 N 197-ФЗ (ред. от 06.04.2024);

32. ГОСТ 12.0.003-2015 Опасные и вредные производственные факторы. Классификация. Перечень опасных и вредных факторов;

33. Федеральный закон «Об обязательном социальном страховании от несчастных случаев на производстве и профессиональных заболеваний» от 24.07.1998 N125-ФЗ;

34. СанПиН 1.2.3685-21 Гигиенические нормативы и требования к обеспечению безопасности и (или) безвредности для человека факторов среды обитания;

35. ГОСТ Р ИСО 9241-4-2009. Эргономические требования к проведению офисных работ с использованием видеодисплейных терминалов (VDT). Часть 5. Требования к расположению рабочей станции и осанке оператора

36. ГОСТ 12.2.032-78 ССБТ. Рабочее место при выполнении работ сидя. Общие эргономические требования. – М.: Изд-во стандартов;

37. ГОСТ 27818-88 Машины вычислительные и системы обработки данных. Допустимые уровни шума на рабочих местах и методы определения.

38. ГОСТ 12.1.003-2014 ССБТ. Шум. Общие требования безопасности.

39. ГОСТ 12.1.003-83 Система стандартов безопасности труда (ССБТ). Шум. Общие требования безопасности
40. СН 2.2.4/2.1.8.566-96 «Производственная вибрация, вибрация в помещениях жилых и общественных зданий»
41. ГОСТ 12.1.012-2004 Система стандартов безопасности труда (ССБТ). Вибрационная безопасность. Общие требования
42. ГОСТ 12.1.038-82 «Электробезопасность. Предельно допустимые значения напряжений прикосновения и токов»;
43. ГОСТ Р 12.1.019-2009 «Электробезопасность. Общие требования и номенклатура видов защиты»;
44. СП 52.13330.2016 Естественное и искусственное освещение. Актуализированная редакция СНиП 23-05-95;
45. ГОСТ Р 55102-2012 «Ресурсосбережение. Обращение с отходами. Руководство по безопасному сбору, хранению, транспортированию и разборке отработавшего электротехнического и электронного оборудования, за исключением ртутьсодержащих устройств и приборов»
46. ГОСТ 17.4.3.04-85 Охрана природы (ССОП). Почвы. Общие требования к контролю и охране от загрязнения
47. ГОСТ Р 53692-2023 Ресурсосбережение. Обращение с отходами. Этапы технологического цикла отходов
48. ГОСТ 12.3.031-83 «Работы со ртутью. Требования безопасности»
49. ГОСТ Р 51768-2001 Ресурсосбережение. Обращение с отходами. Методика определения ртути в ртутьсодержащих отходах. Общие требования
50. ГОСТ Р 55090-2012 Ресурсосбережение. Обращение с отходами. Рекомендации по утилизации отходов бумаги
51. ГОСТ 12.1.004-91 Система стандартов безопасности труда (ССБТ). Пожарная безопасность. Общие требования
52. СП 12.13130.2009 «Определение категорий помещений, зданий и наружных установок по взрывопожарной и пожарной опасности»

53. Приказ Министерства энергетики РФ от 12 августа 2022 г. № 811 «Об утверждении Правил технической эксплуатации электроустановок потребителей электрической энергии»

54. Приказ Министерства труда и социальной защиты РФ от 15 декабря 2020 года № 903н «Об утверждении Правил по охране труда при эксплуатации электроустановок»

55. Правила устройства электроустановок (ПУЭ)

ПРИЛОЖЕНИЕ А

(справочное)

Overview of existing approaches for image captioning

Студент

Группа	ФИО	Подпись	Дата
8BM22	Ямкин Никита Николаевич		

Руководитель ВКР

Должность	ФИО	Ученая степень, звание	Подпись	Дата
Профессор ОИТ ТПУ	Спицын Владимир Григорьевич	д.т.н.		

Консультант-лингвист отделения иностранных языков ШОН

Должность	ФИО	Подпись	Дата
Старший преподаватель ОИЯ ТПУ	Ануфриева Татьяна Николаевна		

1 Overview of existing approaches for image captioning

1.1 The relevance of the task

With the advent of social media, the amount of media content has increased dramatically. This has created a need for effective ways to organize this kind of data and extract it from repositories. One of the approaches to solving this problem is to store images together with their descriptions.

Since the descriptions reflect information about the visual content of the images, this allows you to search for relevant keywords in natural language.

However, manually «decrypting» a large volume of images and videos is too long, expensive and inefficient. In this regard, there is a need for automatic generation of a text description using mathematical models.

1.2 Traditional approaches

The principle of operation is as follows: the model receives an input image, analyzes its content and outputs its characteristics in the form of one or more sentences.

Initially, the problem of automatic generation was solved without the use of deep learning, and all methods were based on certain rules for generating answers and on statistics.

One of the first such approaches is an algorithm developed in 2010 by the team of Farhadi et al [1]. The proposed model uses a meaning space in the format <object, action, scene>, which reflects the meaning of both the image and the description. As a result, the input data is mapped into a given space and then the semantic similarity between them is evaluated. Finally, the semantically closest sentence is used as the image title.

To train this model, the PASCAL1K dataset is used, which contains triplets <object, action, scene>, images and descriptions.




Figure 1 – Illustration of the image space, the meaning space and the description space

The second non-neural network approach to solving the task was based on the template mechanism.

In 2013, the Kulkarni et al team for the first time used computer vision algorithms in conjunction with a graph system to generate descriptions [2].




Figure 2 – Illustration of the algorithm of the Kulkarni et al team

The principle of operation is as follows: first, objects in the image are detected, each of which is assigned attributes reflecting their properties. Then each pair of detected objects is compared with each other to assess the relationship. After that, a Conditional Random Field (CRF) graph is constructed, the nodes of which are the objects themselves, their relationship and properties. The CRF model outputs

a prediction of a sequence of objects, attributes, and relationships between two objects. Next, the predicted sequence is used to form a sentence using ready-made templates.

The above traditional methods have a number of common disadvantages:

- they always generate boilerplate and, often, incoherent text;
- some of them are based on manually extracting features from images;
- unable to account for complex, non-linear relationships and dependencies

between various aspects of images and text;

- highly limited in scalability.

The use of neural networks avoids these limitations.

1.3 Approaches with neural networks

1.3.1 CNN +LSTM

In 2015, Oriol Vinyals et al., in the article Show and Tell: A Neural ImageCaption Generator, proposed a Neural ImageCaption (NIC) model that combines CNN and RNN architectures [4].

The idea is to use the CNN architecture as an image encoder that will encode the image into a vector of its fixed-length features. To do this, the last layer is removed in the classic CNN for image classification.

The LSTM architecture is used as a model for text generation. In this case, the vectors of hidden states are initialized by outputs from CNN.




Figure 3 – Pipeline for Image Captioning model




Figure 4 – NIC architecture

In the period from 2015 to 2018, the NIC architecture was refined: its various modifications, training methods and metrics for evaluating the quality of the generated text were studied.

A further improvement in the quality of the description formation to the image was the integration of the attention mechanism.

1.3.2 CNN + Transformer Decoder

In 2017, the Transformer architecture was introduced.

The next stage of development was the adaptation of the transformer to solve the problem under consideration.

Zhu et al. in 2018, he modified the architecture, replacing the standard transformer encoder with the CNN [5].

The model contains two components, an encoder and a decoder. Now the encoder is a CNN, and the decoder is a transformer.

The principle of operation of the model is similar to NIC, only now the image features are fed to the Multi-Head Attention layer in the transformer decoder.




Figure 5 – Neural network architecture

1.3.3 CNN + Transformer

Another modification in 2018 was proposed by Zhang et al. In this variant, the output from the CNN model is fed to the transformer encoder [6]. This makes it possible to model dependencies between different features of the image, which improves the quality of the entire model.

In this model the encoder is a CNN, and the decoder is a transformer.




Figure 6 – Neural network architecture (Zhang et al)

In this work, three neural network architectures will be implemented for the Image Captioning task.

2 References

1. Farhadi, A. *et al.* (2010). Every Picture Tells a Story: Generating Sentences from Images. In: Daniilidis, K., Maragos, P., Paragios, N. (eds) Computer Vision – ECCV 2010. ECCV 2010. Lecture Notes in Computer Science, vol 6314. Springer, Berlin, Heidelberg. https://doi.org/10.1007/978-3-642-15561-1_2
2. Kulkarni G. *et al.* Babytalk: Understanding and generating simple image descriptions //IEEE transactions on pattern analysis and machine intelligence. – 2013. – Т. 35. – №. 12. – С. 2891-2903.
3. Nallapaneni S. S., Konakanchi S. A Comprehensive Analysis of Real-World Image Captioning and Scene Identification //arXiv preprint arXiv:2308.02833. – 2023.
4. Vinyals O. *et al.* Show and tell: A neural image caption generator //Proceedings of the IEEE conference on computer vision and pattern recognition. – 2015. – С. 3156-3164.
5. Zhu X. *et al.* Captioning transformer with stacked attention modules //Applied Sciences. – 2018. – Т. 8. – №. 5. – С. 739.
6. «Практика по машинному обучению. Задача Image Captioning - описание изображения текстом нейросетью.» // YouTube. [Electronic resource]. URL: <https://www.youtube.com/watch?v=wSVnlLV29VY&t=1726s>

ПРИЛОЖЕНИЕ Б

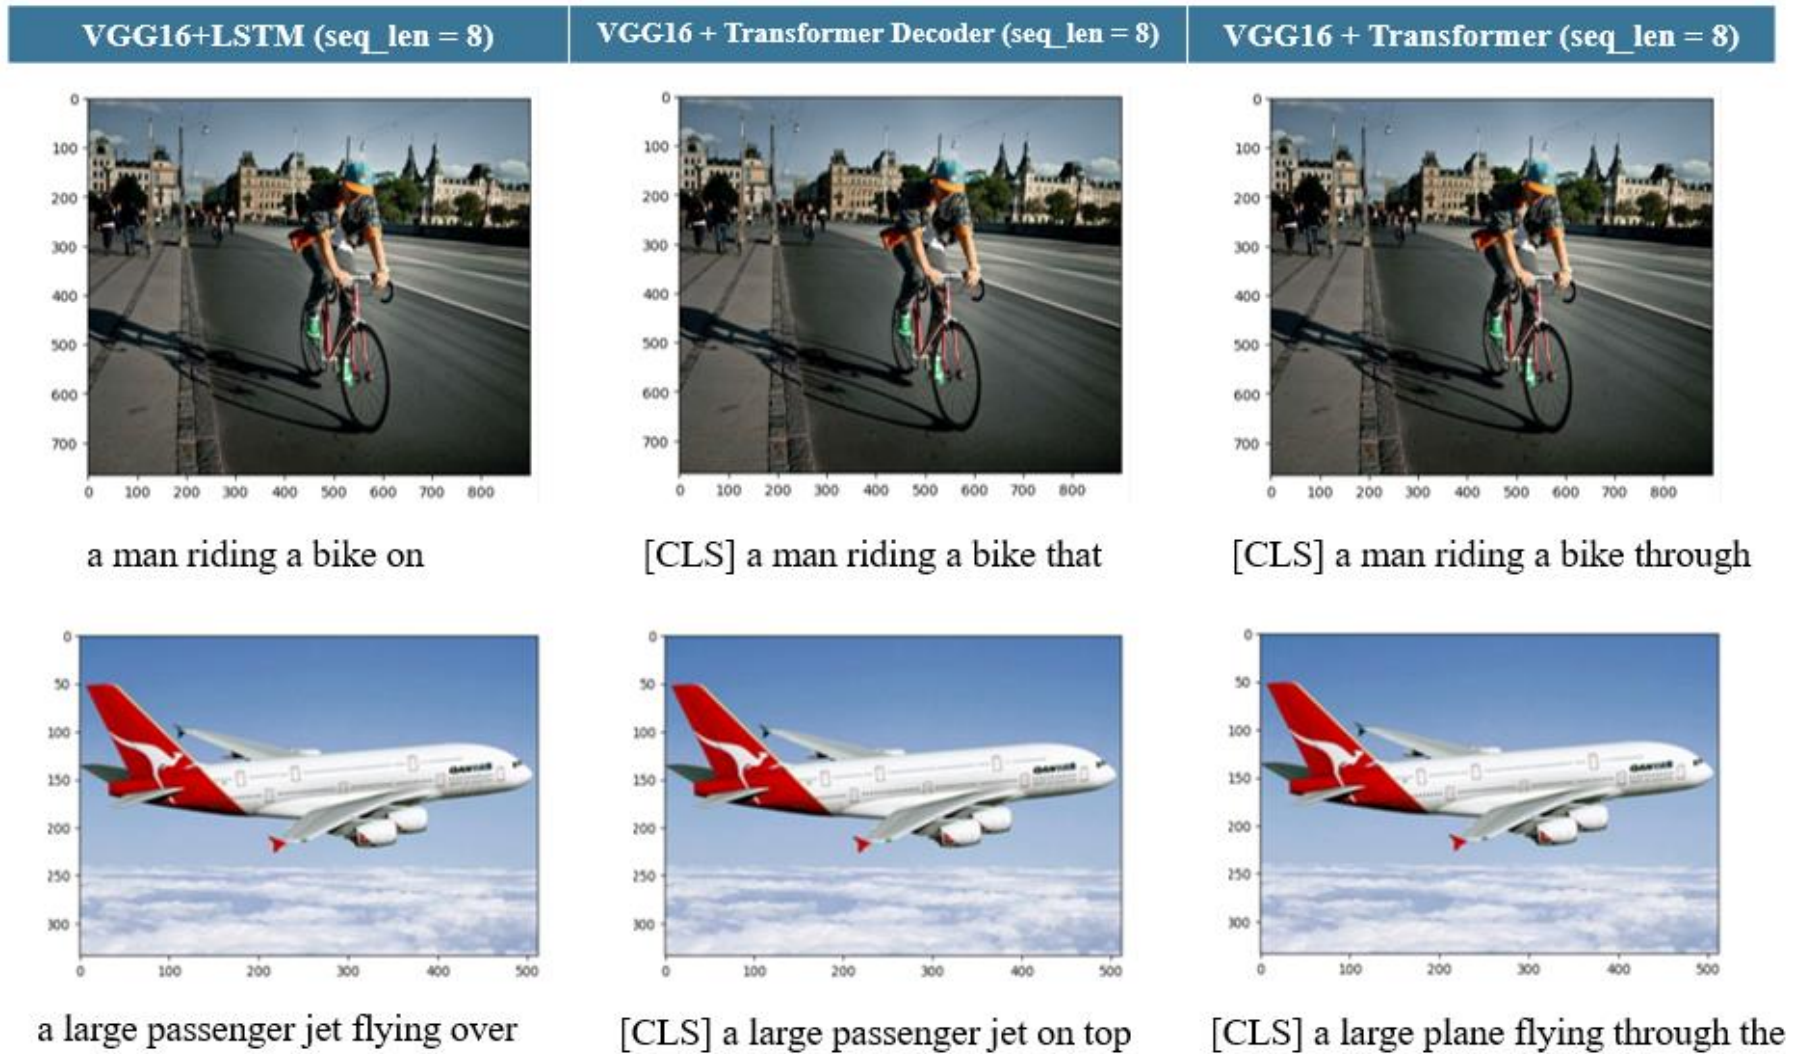


Рисунок Б.1 – Результаты эксперимента 1. Длина последовательности 8 токенов

ПРОДОЛЖЕНИЕ ПРИЛОЖЕНИЯ Б




VGG16+LSTM (seq_len = 8)	VGG16 + Transformer Decoder (seq_len = 8)	VGG16 + Transformer (seq_len = 8)
 a truck with a large white	 [CLS] a bus car on the corner	 [CLS] a small child in a field
 a baseball player holding a baseball	 [CLS] a baseball player holding a baseball	 [CLS] a baseball player holding a bat

Рисунок Б.2 – Результаты эксперимента 1. Длина последовательности 8 токенов

КОНЕЦ ПРИЛОЖЕНИЯ Б




Рисунок Б.3 – Динамика изменения метрик во время обучения модели

ПРИЛОЖЕНИЕ В




Рисунок В.1 – Результаты эксперимента 1. Длина последовательности 12 токенов

ПРОДОЛЖЕНИЕ ПРИЛОЖЕНИЯ В

VGG16+LSTM (seq_len = 12)



a man riding a skateboard on a cement ramp .

VGG16 + Transformer Decoder (seq_len = 12)



[CLS] a man wearing a skateboard trick on a skateboard .

VGG16 + Transformer (seq_len = 12)



[CLS] a man riding a skateboard up a skateboard up a



a refrigerator with a bunch of food in it



[CLS] a refrigerator and white plate filled with food .



[CLS] a glass table with three glass vase of food .

Рисунок В.2 – Результаты эксперимента 1. Длина последовательности 12 токенов

КОНЕЦ ПРИЛОЖЕНИЯ В




Рисунок В.3 – Результаты эксперимента 1. Длина последовательности 12 токенов

ПРИЛОЖЕНИЕ Г

VGG16+LSTM (seq_len = 16)	VGG16 + Transformer Decoder (seq_len = 16)	VGG16 + Transformer (seq_len = 16)
 a red and white car colliding with a man on a motorcycle	 [CLS] a car parked next to a car covered car .	 [CLS] a car parked in front of a parking lot .
 two horses standing on a lush green field .	 [CLS] a group of horses grazing next to a brown horse .	 [CLS] a man standing in front of a brown horse in the water .

Рисунок Г.1 – Результаты эксперимента 1. Длина последовательности 16 токенов

ПРОДОЛЖЕНИЕ ПРИЛОЖЕНИЯ Г




VGG16+LSTM (seq_len = 16)	VGG16 + Transformer Decoder (seq_len = 16)	VGG16 + Transformer (seq_len = 16)
 a close up of a hot dog with ketchup and mustard	 [CLS] a hot dog on a plate with a plate .	 [CLS] a hot dog in the middle of a bun .
 a man is looking at a stove with microwave .	 [CLS] a little girl with a stove , and holding a plate of food .	 [CLS] a person holding a pizza in front of a microwave .

Рисунок Г.2 – Результаты эксперимента 1. Длина последовательности 16 токенов

КОНЕЦ ПРИЛОЖЕНИЯ Г





Рисунок Г.3 – Динамика изменения метрик во время обучения модели

ПРИЛОЖЕНИЕ Д


Efficientnet_v2_s + Transformer Decoder (seq_len = 12)

VGG16 + Transformer Decoder (seq_len = 12)


ResNet18 + Transformer Decoder (seq_len = 12)



[CLS] a cat are player that are player
##ing head out



[CLS] a dog that is standing in the grass .



[CLS] a man standing on a tennis court
holding a racquet



[CLS] a city street with a city street at a street



[CLS] an airplane is flying through the air while flying over



[CLS] a man is riding a wave on top of a

Рисунок Д.1 – Результаты эксперимента 2

ПРИЛОЖЕНИЕ Е

VGG16 + Transformer Decoder (seq_len = 12,
n_head = 8)



[CLS] a dog standing in a dog with a dog in

VGG16 + Transformer Decoder (seq_len = 12,
n_head = 16)



[CLS] a dog with a dog and a brown in

VGG16 + Transformer Decoder (seq_len = 12,
n_head = 64)



[CLS] a dog and dog standing in front of a dog



[CLS] a kitchen with a pile of food in a kitchen



[CLS] a kitchen with a refrigerator and a refrigerator .



[CLS] a kitchen filled with lots of food in a kitchen

Рисунок Е.1 – Результаты эксперимента 3